

**ANALISIS PERBANDINGAN PERFORMA ALGORITMA  
*RANDOM FOREST* DAN *DECISION TREE* DALAM  
INDIKATOR EKONOMI INDONESIA**



**SKRIPSI**

Diajukan untuk memenuhi salah satu syarat kelulusan Program Sarjana

**SECHAN ARYATAMA**

**NIM : 17210565**

**Program Studi Teknologi Informasi**

**Fakultas Teknik dan Informatika**

**Universitas Bina Sarana Informatika**

**Jakarta**

**2025**

## SURAT PERNYATAAN KEASLIAN SKRIPSI PADA PROGRAM SARJANA

Yang bertanda tangan di bawah ini:

Nama : Sechan Aryatama  
NIM : 17210565  
Jenjang : Sarjana (S1)  
Program Studi : Teknologi Informasi  
Fakultas : Teknik dan Informatika  
Perguruan Tinggi : Universitas Bina Sarana Informatika

Dengan ini menyatakan bahwa Skripsi yang telah saya buat dengan judul : **“Analisis Perbandingan Performa Algoritma *Random Forest* dan *Decision Tree* Dalam Indikator Ekonomi Indonesia”**, adalah asli (orisinal) atau tidak plagiat (menjiplak) dan belum pernah diterbitkan/dipublikasikan dimanapun dan dalam bentuk apapun.

Demikianlah surat pernyataan ini saya buat dengan sebenar-benarnya tanpa ada paksaan dari pihak manapun juga. Apabila di kemudian hari ternyata saya memberikan keterangan palsu dan atau ada pihak lain yang mengklaim bahwa Skripsi yang telah saya buat adalah hasil karya milik seseorang atau badan tertentu, saya bersedia diproses baik secara pidana maupun perdata dan kelulusan saya dari Universitas Bina Sarana Informatika dicabut/dibatalkan.

Dibuat di : Jakarta

Pada tanggal : 03 Juli 2025

Yang menyatakan,



**Sechan Aryatama**

## SURAT PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS

Yang bertanda tangan di bawah ini, saya :

Nama : Sechan Aryatama  
NIM : 17210565  
Jenjang : Sarjana(S1)  
Program Studi : Teknologi Informasi  
Fakultas : Teknik dan Informatika  
Perguruan Tinggi : Universitas Bina Sarana Informatika

Dengan ini menyatakan bahwa seluruh data, informasi, interpretasi serta pernyataan yang terdapat dalam karya ilmiah Penulis dengan judul “**ANALISIS PERBANDINGAN PERFORMA ALGORITMA *RANDOM FOREST* DAN *DECISION TREE* DALAM INDIKATOR EKONOMI INDONESIA**” ini kecuali yang disebutkan sumbernya adalah hasil pengamatan, penelitian, pengelolaan, serta pemikiran saya.

Penulis menyetujui untuk memberikan ijin kepada pihak **Universitas Bina Sarana Informatika** untuk mendokumentasikan karya ilmiah saya tersebut secara internal dan terbatas, serta tidak untuk mengunggah karya ilmiah Penulis pada repository Universitas Bina Sarana Informatika. Demikian pernyataan ini saya buat dengan sebenarnya.

Penulis bersedia untuk bertanggung jawab secara pribadi, tanpa melibatkan pihak **Universitas Bina Sarana Informatika**, atas materi/isi karya ilmiah tersebut, termasuk bertanggung jawab atas dampak atau kerugian yang timbul dalam bentuk akibat tindakan yang berkaitan dengan data, informasi, interpretasi serta pernyataan yang terdapat pada karya ilmiah saya ini.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Jakarta

Pada tanggal : 03 Juli 2025

Yang menyatakan,



**Sechan Aryatama**

## PERSETUJUAN DAN PENGESAHAN SKRIPSI

Skripsi ini diajukan oleh:

Nama : Sechan Aryatama  
NIM : 17210565  
Jenjang : Sarjana (S1)  
Program Studi : Teknologi Informasi  
Fakultas : Teknik dan Informatika  
Perguruan Tinggi : Universitas Bina Sarana Informatika  
Judul Skripsi : Analisis Perbandingan Performa Algoritma Random Forest  
Dan Decision Tree Dalam Indikator Ekonomi Indonesia

Telah dipertahankan pada periode 2025-1 dihadapan penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh Sarjana Komputer (S.Kom) pada Program Sarjana (S1) Program Studi Teknologi Informasi di Universitas Bina Sarana Informatika.

Jakarta, 28 Juli 2025

### PEMBIMBING SKRIPSI

Pembimbing I : Kukuh Panggalih, M.Kom.





Ditandatangani Digital:  
Kukuh Panggalih  
2025-06-11 09:34:09

### DEWAN PENGUJI

Penguji I : Harsih Rianto, M.Kom.





Ditandatangani Digital:  
Harsih Rianto  
28-07-2025 17:07:23

Penguji II : Mochammad Abdul Azis, M.Kom.





Ditandatangani Digital:  
Mochammad Abdul Azis  
28-07-2025 16:47:08



## PEDOMAN PENGGUNAAN HAK CIPTA

Skripsi sarjana yang berjudul “**Analisis Perbandingan Performa Algoritma *Random Forest* dan *Decision Tree* Dalam Indikator Ekonomi Indonesia**” adalah hasil karya tulis asli Sechan Aryatama dan bukan hasil terbitan sehingga peredaran karya tulis hanya berlaku dilingkungan akademik saja, serta memiliki hak cipta. Oleh karena itu, dilarang keras untuk menggandakan baik sebagian maupun seluruhnya karya tulis ini, tanpa seizin penulis.

Referensi kepustakaan diperkenankan untuk dicatat tetapi pengutipan atau peringkasan isi tulisan hanya dapat dilakukan dengan seizin penulis dan disertai ketentuan pengutipan secara ilmiah dengan menyebutkan sumbernya.

Untuk keperluan perizinan pada pemilik dapat menghubungi informasi yang tertera di bawah ini:



Nama : Sechan Aryatama  
Alamat : Jl Jatibening 2 no 31 Rt 01/02  
No. Telp : 081312615456  
E-mail : sechanaryatama23478@gmail.com

|                                                                                   |                                            |
|-----------------------------------------------------------------------------------|--------------------------------------------|
|  | <b>LEMBAR KONSULTASI SKRIPSI</b>           |
|                                                                                   | <b>UNIVERSITAS BINA SARANA INFORMATIKA</b> |

NIM : 17210565  
 Nama Lengkap : Sechan Aryatama  
 Dosen Pembimbing : Kukuh Panggalih, M.Kom  
 Judul Skripsi : Analisis Perbandingan Performa Algoritma *Random Forest* dan *Decision Tree* Dalam Indikator Ekonomi Indonesia

| No | Tanggal Bimbingan | Pokok Bahasan                                 | Paraf Dosen Pembimbing                                                                                                                                                  |
|----|-------------------|-----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | 08 April 2025     | Pengajuan Judul , Tema , dan Metode           |   |
| 2  | 23 April 2025     | Melakukan Perbandingan Negara Lainnya         |                                                                                                                                                                         |
| 3  | 30 April 2025     | Cek Laporan Bab 1                             |                                                                                                                                                                         |
| 4  | 08 Mei 2025       | Memahami analisis <i>Machine Learning</i>     |                                                                                                                                                                         |
| 5  | 16 Mei 2025       | Memahami hasil analisis dan Cek Laporan Bab 2 |                                                                                                                                                                         |
| 6  | 22 Mei 2025       | Cek Laporan Bab 3                             |                                                                                                                                                                         |
| 7  | 12 Juni 2025      | Memahami Pembahasan Laporan Bab 4             |                                                                                                                                                                         |
| 8  | 02 Juli 2025      | Cek laporan - project/penelitian              |                                                                                                                                                                         |

Catatan untuk Dosen Pembimbing.

Bimbingan Skripsi

Dimulai pada tanggal : 08 April 2025  
 Diakhiri pada tanggal : 02 Juli 2025  
 Jumlah pertemuan bimbingan : 8 pertemuan

Disetujui oleh,  
Dosen Pembimbing




Otentikasi Digital  
 Kukuh Panggalih  
 2025-07-02 18:54:00

(Kukuh Panggalih, M.Kom)

## LEMBAR PERSEMBAHAN

Dengan segala kerendahan hati dan rasa syukur yang tiada terhingga, kupersembahkan karya ini. Setiap huruf yang tertulis adalah cerminan dari perjuangan, doa, dan ketulusan hati. Puji syukur tak terhingga kepada Allah Subhanahu Wa Ta'ala, Tuhan semesta alam, atas segala limpahan rahmat, hidayah, dan karunia-Nya yang tak terputus. Berkat izin dan kekuatan-Nya, skripsi ini dapat terselesaikan dengan baik.

Persembahan tulus ini kuberikan kepada:

1. Kedua orang tuaku tercinta, Ayahanda dan Ibunda. Tiada kata yang sanggup merangkai besarnya pengorbanan, cinta tulus, dan doa yang tak pernah henti kalian panjatkan. Kalian adalah inspirasi abadi, penopang utama, dan pelita yang tak pernah padam dalam setiap langkah hidupku. Terima kasih atas setiap tetes keringat, setiap pengorbanan, dan setiap kasih sayang yang tak terbatas. Semoga Allah SWT senantiasa melimpahkan kebahagiaan dan kesehatan bagi kalian berdua.
2. Seluruh keluarga besar yang senantiasa memberikan dukungan, semangat, dan kebersamaan yang tak ternilai harganya.
3. Bapak Kukuh Panggalih, M.Kom selaku Dosen Pembimbing Skripsi. Terima kasih atas bimbingan, arahan, ilmu yang tak pelit dibagi, serta kesabaran yang luar biasa dalam membimbingku hingga karya ini selesai.
4. Sahabat-sahabat seperjuangan dan teman-teman terbaikku yang selalu hadir dengan dukungan, tawa, dan cerita. Kalian adalah bagian tak terpisahkan dari perjalanan ini
5. Dan untuk diriku sendiri, yang telah melewati berbagai tantangan, rintangan, dan pengorbanan waktu serta pikiran. Terima kasih atas kegigihan, kesabaran, dan keyakinan untuk tidak menyerah hingga titik ini. Ini adalah bukti bahwa setiap usaha keras akan membuahkan hasil.

## KATA PENGANTAR

Alhamdulillah, dengan segala puji dan syukur kehadirat Allah SWT, atas rahmat serta karunia-Nya, tugas akhir ini berhasil saya selesaikan dengan baik. Skripsi ini, yang disajikan dalam format sederhana, berjudul "**Analisis Perbandingan Performa Algoritma Random Forest dan Decision Tree Dalam Indikator Ekonomi Indonesia**", disusun sebagai salah satu syarat untuk kelulusan dari Program Sarjana Universitas Bina Sarana Informatika.

Materi penulisan skripsi ini bersumber dari hasil penelitian yang telah saya lakukan, serta didukung oleh berbagai literatur dan referensi yang relevan. Saya sepenuhnya menyadari bahwa kelancaran dan penyelesaian skripsi ini tidak akan terwujud tanpa bimbingan serta dorongan dari banyak pihak. Oleh karena itu, pada kesempatan ini, saya ingin menyampaikan ucapan terima kasih yang tulus kepada:

1. Ketua Program Studi Universitas Bina Sarana Informatika.
2. Bapak Kukuh Panggalih, M.Kom selaku Dosen Pembimbing Skripsi.
3. Seluruh staf, karyawan, dan dosen di lingkungan Universitas Bina Sarana Informatika.
4. Orang tua tercinta yang telah memberikan dukungan moral maupun spiritual.
5. Rekan-rekan mahasiswa kelas 17.8A.11

Terima kasih tak terhingga juga saya sampaikan kepada semua pihak yang telah berkontribusi besar dalam terwujudnya skripsi ini, yang saya sadari masih jauh dari sempurna. Oleh karena itu, masukan dan saran membangun sangat saya harapkan demi peningkatan kualitas penulisan di masa mendatang. Semoga skripsi ini bermanfaat bagi saya dan para pembaca.

Jakarta 03 juli 2025

Penulis



**Sechan Aryatama**

## ABSTRAKSI

**Sechan Aryatama(17210565), Analisis Perbandingan Performa Algoritma *Random Forest* dan *Decision Tree* Dalam Indikator Ekonomi Indonesia**

Kajian ini membandingkan kinerja algoritma *Random Forest* dan *Decision Tree* dalam menganalisis serta memprediksi pola *Gross Domestic Product (GDP) Deflator* Indonesia. Pentingnya pemahaman dan prediksi ekonomi makro mendorong penggunaan *machine learning* untuk mengatasi kompleksitas data ekonomi.

Tujuan studi adalah membandingkan kedua algoritma berdasarkan metrik MSE,  $R^2$ , dan MAPE, mengidentifikasi variabel ekonomi dominan, dan menentukan algoritma optimal. Data indikator ekonomi Indonesia dari *OECD Data Explorer* (2010-2022) digunakan, dengan *GDP Deflator* sebagai variabel target. Variabel independen mencakup *Labour tax revenue* dan *Nominal exchange rate*. Data diproses, dan model diimplementasikan menggunakan *Python*.

Hasil menunjukkan *Decision Tree* secara konsisten mengungguli *Random Forest* dalam akurasi dan tingkat kesalahan yang lebih rendah. Analisis *feature importance* menyoroti pendapatan pajak tenaga kerja dan nilai tukar nominal sebagai faktor paling berpengaruh. Meskipun *Random Forest* sering lebih stabil, *Decision Tree* terbukti lebih efektif dalam memodelkan *GDP Deflator* Indonesia.

**Kata Kunci :** *Machine Learning*, *Random Forest*, *Decision Tree* , *GDP Deflator*, Indikator Ekonomi, Indonesia.



## ABSTRACT

***Sechan Aryatama(17210565), Comparative Analysis of Random Forest and Decision Tree Algorithm Performance on Indonesian Economic Indicators***

*This study compares the performance of Random Forest and Decision Tree algorithms in analyzing and predicting patterns in Indonesia's Gross Domestic Product (GDP) Deflator. The importance of understanding and predicting macroeconomics has led to the use of machine learning to address the complexity of economic data.*

*The study aims to compare the two algorithms based on MSE,  $R^2$ , and MAPE metrics, identify dominant economic variables, and determine the optimal algorithm. Indonesian economic indicator data from the OECD Data Explorer (2010-2022) was used, with GDP Deflator as the target variable. Independent variables include Labor tax revenue and Nominal exchange rate. Data was processed, and models were implemented using Python.*

*The results show that Decision Tree consistently outperforms Random Forest in terms of accuracy and lower error rates. Feature importance analysis highlights labor tax revenue and nominal exchange rate as the most influential factors. Although Random Forest is often more stable, Decision Tree proves to be more effective in modeling Indonesia's GDP Deflator.*

***Keywords: Machine Learning, Random Forest, Decision Tree, GDP Deflator, Economic Indicators, Indonesia.***

## DAFTAR ISI

|                                                                                        |      |
|----------------------------------------------------------------------------------------|------|
| LEMBAR JUDUL SKRIPSI.....                                                              | i    |
| SURAT PERNYATAAN KEASLIAN SKRIPSI PADA PROGRAM SARJANA .....                           | ii   |
| SURAT PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK<br>KEPENTINGAN AKADEMIS..... | iii  |
| PERSETUJUAN DAN PENGESAHAN SKRIPSI .....                                               | iv   |
| PEDOMAN PENGGUNAAN HAK CIPTA .....                                                     | v    |
| LEMBAR PERSEMBAHAN .....                                                               | vii  |
| KATA PENGANTAR.....                                                                    | viii |
| ABSTRAKSI .....                                                                        | ix   |
| ABSTRACT.....                                                                          | x    |
| DAFTAR ISI .....                                                                       | xi   |
| DAFTAR GAMBAR .....                                                                    | xiv  |
| DAFTAR TABEL.....                                                                      | xv   |
| DAFTAR LAMPIRAN .....                                                                  | xvi  |
| BAB I PENDAHULUAN.....                                                                 | 1    |
| 1.1. Latar Belakang Masalah.....                                                       | 1    |
| 1.2. Identifikasi Permasalahan .....                                                   | 2    |
| 1.3. Perumusan Masalah .....                                                           | 3    |
| 1.4. Tujuan dan Manfaat .....                                                          | 3    |
| 1.5. Metode Penelitian.....                                                            | 4    |
| 1.6. Teknik Pengumpulan Data .....                                                     | 5    |
| 1.7. Ruang Lingkup.....                                                                | 6    |
| 1.8. Hipotesis.....                                                                    | 8    |
| BAB II LANDASAN TEORI .....                                                            | 9    |
| 2.1. Tinjauan Pustaka .....                                                            | 9    |
| 2.1.1. OECD ( <i>Organization for Economic Cooperation and Development</i> ) .         | 9    |
| 2.1.2. Pengertian Indikator Ekonomi .....                                              | 10   |
| 2.1.3. Pengertian Machine Learning .....                                               | 11   |
| 2.1.4. Supervised Learning.....                                                        | 11   |



|                                    |                                                                |    |
|------------------------------------|----------------------------------------------------------------|----|
| 2.1.5.                             | Pengertian <i>python</i> .....                                 | 13 |
| 2.1.6.                             | Pengertian Google Colab .....                                  | 14 |
| 2.1.7.                             | Penelitian Terkait.....                                        | 14 |
| BAB III METODOLOGI PENELITIAN..... |                                                                | 16 |
| 3.1.                               | Tahapan Penelitian .....                                       | 16 |
| 3.1.1.                             | Identifikasi Permasalahan .....                                | 17 |
| 3.1.2.                             | Studi Literatur .....                                          | 17 |
| 3.1.3.                             | Pengumpulan Data .....                                         | 17 |
| 3.1.4.                             | Preprocessing Data.....                                        | 17 |
| 3.1.5.                             | Exploratory Data Analysis (EDA) .....                          | 18 |
| 3.1.6.                             | Implementasi Algoritma.....                                    | 18 |
| 3.1.7.                             | Hasil Evaluasi Model.....                                      | 18 |
| 3.2.                               | Instrument Penelitian .....                                    | 19 |
| 3.2.1.                             | Perangkat Keras .....                                          | 19 |
| 3.2.2.                             | Perangkat Lunak.....                                           | 19 |
| 3.3.                               | Metode Pengumpulan Data, Populasi, dan Sample Penelitian ..... | 19 |
| 3.3.1.                             | Metode Pengumpulan Data.....                                   | 19 |
| 3.3.2.                             | Populasi Penelitian.....                                       | 20 |
| 3.3.3.                             | Sampel Penelitian.....                                         | 20 |
| 3.4.                               | Metode Analisis Data .....                                     | 20 |
| 3.4.1.                             | Preprocessing Data.....                                        | 20 |
| 3.4.2.                             | Eksplorasi Data Analysis (EDA).....                            | 21 |
| 3.4.3.                             | Implementasi Algoritma Machine Learning .....                  | 22 |
| 3.4.4.                             | Evaluasi Model.....                                            | 22 |
| 3.4.5.                             | Analisis Feature Importance .....                              | 23 |
| 3.4.6.                             | Pengujian Hipotesis.....                                       | 23 |
| BAB IV HASIL DAN PEMBAHASAN.....   |                                                                | 24 |
| 4.1.                               | Deskripsi Dataset .....                                        | 24 |
| 4.2.                               | Hasil Pra-Pemrosesan Data .....                                | 25 |
| 4.2.1.                             | Missing Value.....                                             | 25 |
| 4.2.2.                             | Hasil Duplikat .....                                           | 26 |
| 4.2.3.                             | Hasil Outlier dan Penanganan Outlier.....                      | 26 |
| 4.2.4.                             | Hasil <i>Exploratory Data Analysis</i> (EDA).....              | 28 |

|                                                                                   |                                                            |    |
|-----------------------------------------------------------------------------------|------------------------------------------------------------|----|
| 4.3.                                                                              | Implementasi Algoritma.....                                | 29 |
| 4.3.1.                                                                            | Implementasi <i>Random Forest</i> .....                    | 30 |
| 4.3.2.                                                                            | Implementasi <i>Decision Tree</i> .....                    | 30 |
| 4.4.                                                                              | Hasil Evaluasi Model .....                                 | 30 |
| 4.4.1.                                                                            | Perbandingan Kinerja Algoritma.....                        | 31 |
| 4.4.2.                                                                            | Hasil Feature Importance .....                             | 31 |
| 4.4.3.                                                                            | Hasil Visualisasi <i>Decision Tree</i> .....               | 32 |
| 4.5.                                                                              | Pembahasan.....                                            | 33 |
| 4.5.1.                                                                            | Perbandingan Kinerja Random Forest dan Decision Tree ..... | 34 |
| 4.5.2.                                                                            | Pengaruh Variabel <i>Importance</i> .....                  | 34 |
| 4.5.3.                                                                            | Stabilitas Akurasi .....                                   | 35 |
| 4.5.4.                                                                            | Hasil Prediksi <i>GDP Deflator</i> .....                   | 36 |
| BAB V PENUTUP.....                                                                |                                                            | 38 |
| 5.1.                                                                              | Kesimpulan .....                                           | 38 |
| 5.2.                                                                              | Saran.....                                                 | 39 |
| DAFTAR PUSTAKA .....                                                              |                                                            | 41 |
| DAFTAR RIWAYAT HIDUP.....                                                         |                                                            | 43 |
| SURAT PERNYATAAN KEBENARAN/KEABSAHAN DATA HASIL RISET<br>UNTUK KARYA ILMIAH ..... |                                                            | 44 |
| PENGECEKAN PLAGIARISME .....                                                      |                                                            | 45 |
| LAMPIRAN.....                                                                     |                                                            | 46 |

## DAFTAR GAMBAR

|                                                |    |
|------------------------------------------------|----|
| Gambar III. 1 Metodologi Penelitian .....      | 16 |
| Gambar IV. 1 Dataset .....                     | 25 |
| Gambar IV. 2 Missing Value .....               | 25 |
| Gambar IV. 3 Hasil Duplikat.....               | 26 |
| Gambar IV. 4 Hasil Outlier .....               | 26 |
| Gambar IV. 5 Setelah Penanganan Outlier.....   | 27 |
| Gambar IV. 6 Distribusi Data.....              | 28 |
| Gambar IV. 7 Korelasi.....                     | 29 |
| Gambar IV. 8 Perbandingan Algoritma.....       | 31 |
| Gambar IV. 9 Feature Importance .....          | 32 |
| Gambar IV. 10 Visualisasi Decision Tree.....   | 33 |
| Gambar IV. 11 Hasil Prediksi GDP DEFLATOR..... | 36 |



## DAFTAR TABEL

|                                                |    |
|------------------------------------------------|----|
| Tabel II. 1 Penelitian Terkait .....           | 14 |
| Tabel III. 1 Perangkat Keras.....              | 19 |
| Tabel III. 2 Perangkat Lunak.....              | 19 |
| Tabel III. 3 Implementasi .....                | 22 |
| Tabel IV. 1 Perbandingan Hasil Indonesia ..... | 34 |



## DAFTAR LAMPIRAN

|                                                                                |    |
|--------------------------------------------------------------------------------|----|
| Lampiran 1 Import Library .....                                                | 46 |
| Lampiran 2 Load Dataset .....                                                  | 46 |
| Lampiran 3 Menampilkan Informasi .....                                         | 46 |
| Lampiran 4 Ganti Nama Kolom .....                                              | 47 |
| Lampiran 5 Menampilkan Beberapa Data Frame .....                               | 47 |
| Lampiran 6 Menampilkan Array .....                                             | 47 |
| Lampiran 7 Menampilkan Data keseluruhan .....                                  | 47 |
| Lampiran 8 Mengecek Missing Value .....                                        | 47 |
| Lampiran 9 Memeriksa Duplikat .....                                            | 48 |
| Lampiran 10 Menampilkan Outlier .....                                          | 48 |
| Lampiran 11 Menangani Outlier .....                                            | 48 |
| Lampiran 12 Menampilkan Korelasi Antar Fitur .....                             | 48 |
| Lampiran 13 Import Random Forest dan Decision Tree .....                       | 49 |
| Lampiran 14 Menampilkan Hasil .....                                            | 50 |
| Lampiran 15 Menampilkan Feature Importance dan visualisasi Decision Tree ..... | 51 |
| Lampiran 16 Menampilkan Hasil Prediksi GDP DEFLATOR .....                      | 52 |



# BAB I

## PENDAHULUAN

### 1.1. Latar Belakang Masalah

Struktur ekonomi sebuah negara tidak terlepas oleh berbagai indikator yang menunjukkan kondisi fundamentalnya, seperti inflasi, nilai tukar, pendapatan nasional, *Gross Domestic Product (GDP)*, dan tingkat pengangguran. “Perekonomian Indonesia selalu mengalami fluktuasi setiap tahun, banyak faktor yang mempengaruhi fluktuasi tersebut, salah satunya adalah kebijakan moneter, kebijakan moneter memiliki peranan penting dalam menjaga stabilitas ketahanan perekonomian Indonesia khususnya pada tingkat Makro dalam suatu negara.”(Ramadhani. P & Hasanah, 2024)

Dalam indikator ekonomi makro yang sering diperhatikan di tingkat mikro adalah inflasi, tingkat suku bunga, pertumbuhan ekonomi, dan perubahan nilai tukar. Kegiatan ekonomi makro sangat mempengaruhi kegiatan ekonomi di tingkat mikro, termasuk kemampuan seseorang dalam memahami dan memprediksi kondisi ekonomi makro di masa depan yang sangat bermanfaat bagi pengambilan keputusan di tingkat mikro.(Hendajany & Wati, 2020)

Dalam penggunaan teknologi, terutama *machine learning*, menjadi pendekatan yang semakin populer untuk menganalisis dan memprediksi indikator ekonomi. Yang dimana *machine learning*. “*machine learning* adalah istilah yang digunakan untuk merujuk pada cabang ilmu komputer yang mempelajari metode desain algoritma yang mampu mempelajari atau beradaptasi dengan pola data tanpa diprogram secara eksplisit.”(Kurniawan et al., 2023) Dalam *machine learning* ada beberapa algoritma salah satunya *Random Forest* dan *Decision Tree*.



*Random Forest* adalah algoritma *machine learning* yang kuat karena menggabungkan banyak pohon keputusan untuk meningkatkan keakuratan prediksi. Cara kerjanya adalah dengan melatih setiap pohon keputusan pada subset data acak dan menggunakan fitur yang terbatas dari keseluruhan *dataset*. (Rizky et al., 2024)

*Decision Tree* adalah algoritma populer untuk pengambilan keputusan yang bekerja dengan memodelkan solusi masalah sebagai struktur pohon hierarki. Dalam struktur ini, setiap kriteria direpresentasikan sebagai node yang saling terhubung, membentuk jalur yang mengarah pada prediksi atau keputusan akhir. (Pamuji et al., 2021)

Karena hubungan yang kompleks antara berbagai indikator ekonomi, pendekatan analisis yang dapat menangkap pola non-linear dan interaksi yang kompleks antar variabel diperlukan. Metode seperti *Random Forest* dan *Decision Tree* menawarkan keunggulan dalam menganalisis dataset yang memiliki ciri-ciri ini. Metode-metode ini dapat menemukan variabel yang paling penting dan membuat model prediksi yang akurat.

## **1.2. Identifikasi Permasalahan**

1. Adanya korelasi yang kuat antara *GDP deflator* dengan beberapa variabel ekonomi, yang bisa mempengaruhi performa algoritma *Random Forest* dan *Decision Tree*.
2. Dalam menangani variabel-variabel yang memiliki korelasi tinggi, algoritma *Random Forest* dan *Decision Tree* memiliki perbedaan. Hal ini dapat mempengaruhi hasil analisis *GDP Deflator*.
3. Kebutuhan untuk mengidentifikasi variabel-variabel yang paling signifikan dalam mempengaruhi indikator ekonomi utama seperti *GDP Deflator*.

### 1.3. Perumusan Masalah

1. Bagaimana perbandingan kinerja algoritma *Random Forest* dan *Decision Tree* dalam menganalisis GDP deflator Indonesia berdasarkan metrik evaluasi MSE,  $R^2$ , dan MAPE?
2. *variable importance* yang berpengaruh dari *Random Forest* terhadap variabel dengan *GDP deflator*?
3. Manakah dari kedua algoritma yang memberikan performa dan stabilitas analisis lebih baik untuk *GDP deflator*?

### 1.4. Tujuan dan Manfaat

Tujuan dari penulisan skripsi ini adalah:

1. Membandingkan performa algoritma *Random Forest* dan *Decision Tree* dalam menganalisis pola *GDP Deflator* Indonesia.
2. Menentukan faktor ekonomi yang paling berpengaruh terhadap *GDP Deflator*.
3. Menentukan algoritma yang lebih optimal antara *Random Forest* dan *Decision Tree* untuk pemodelan *GDP deflator* Indonesia.
4. Memprediksi *GDP Deflator* Indonesia menggunakan algoritma *Random Forest* dan *Decision Tree*.

Sedangkan untuk manfaat penulisan skripsi ini adalah sebagai berikut:

1. Manfaat untuk penulis

Sebagai salah satu syarat kelulusan Program Sarjana pada Program Studi Teknologi Informasi Universitas Bina Sarana Informatika.

2. Manfaat untuk objek penelitian

a. Memberikan pemahaman mendalam tentang kemampuan algoritma *Random Forest* dan *Decision Tree* dalam memodelkan indikator ekonomi Indonesia.

- b. Mengembangkan pendekatan analisis *feature importance* yang dapat diaplikasikan pada indikator ekonomi makro lainnya.
  - c. mengembangkan teknik pemodelan *GDP Deflator* baru yang dapat diterapkan di negara lain
3. Manfaat untuk pembaca

Menambah pengetahuan dan literatur mengenai penggunaan model *machine learning* dalam analisis data ekonomi, khususnya metode *Random Forest* dan *Decision Tree* dan menyediakan model yang akurat dari pola *GDP Deflator* dengan menerapkan algoritma *Random Forest* dan *Decision Tree* yang paling sesuai.

### 1.5. Metode Penelitian

Metode penelitian yang digunakan dalam studi ini adalah sebagai berikut:

1. Studi Pustaka : Data dikumpulkan dari publikasi, jurnal ilmiah, dan *e-book* yang tersedia di perpustakaan. Studi literatur membantu peneliti memahami subjek penelitian, terutama yang berkaitan dengan analisis perbandingan algoritma dan algoritma *Random Forest* dan *Decision Tree*.
2. Pendekatan Penelitian: dalam penelitian ini digunakan pendekatan kuantitatif dengan rancangan eksperimen. Pendekatan ini dipilih untuk memungkinkan perbandingan yang objektif antara kedua algoritma.
3. Dataset: *Dataset* yang dimanfaatkan dalam penelitian ini akan diambil dari sumber yang relevan dan memiliki karakteristik yang sesuai untuk analisis. Dataset ini akan mencakup variabel yang diperlukan untuk pengujian kedua algoritma.

4. **Preprocessing Data:** Sebelum analisis dilakukan, data akan diproses untuk memastikan kualitasnya. Ini termasuk pembersihan data, penanganan nilai yang hilang.
5. **EDA (*Exploratory Data Analysis*) :** proses menganalisis dataset untuk memahami karakteristik, pola, anomali, dan hubungan antar variabel secara visual dan statistik sebelum melakukan pemodelan.
6. **Implementasi Algoritma:**
  - a. *Decision Tree* akan diimplementasikan menggunakan pustaka *scikit-learn* di *Python*. Model ini akan dilatih menggunakan *dataset* yang telah diproses.
  - b. *Random Forest* juga akan diimplementasikan dengan cara yang sama, dan model ini akan dilatih dengan parameter yang dioptimalkan untuk mendapatkan hasil terbaik.
7. **Evaluasi Model :** Kinerja kedua algoritma akan dievaluasi menggunakan metrik seperti *MAPE (Mean Absolute Percentage Error)*, *MSE (Mean Squared Error)* dan  $R^2$  (*R-squared / Koefisien Determinasi*). Hasil dari kedua model akan dibandingkan untuk menentukan algoritma mana yang lebih efektif dalam konteks dataset yang digunakan.

## 1.6. Teknik Pengumpulan Data

Prosedur pengumpulan data dalam penelitian ini dilaksanakan melalui tahapan-tahapan berikut :

1. **Sumber Data :** Data yang digunakan dalam penelitian ini diambil dari data *OECD explorer*. Dataset yang dipilih relevan dengan topik penelitian dan memiliki variabel yang cukup untuk analisis menggunakan algoritma *Random Forest* dan *Decision Tree*.

2. *Preprocessing* Data : Setelah data diambil, langkah-langkah *preprocessing* akan dilakukan untuk memastikan kualitas data.
  - a. Pembersihan Data : Menghapus atau memperbaiki data yang tidak valid, duplikat, atau tidak konsisten.
  - b. Penanganan Nilai Hilang : Mengidentifikasi dan menangani nilai yang hilang dengan metode yang sesuai, seperti imputasi atau penghapusan.
3. *EDA (Exploratory Data Analysis)* : proses menganalisis dataset untuk memahami karakteristik, pola, anomali, dan hubungan antar variabel secara visual dan statistik sebelum melakukan pemodelan.
4. Implementasi Algoritma:
 

*Decision Tree* akan diimplementasikan menggunakan pustaka *scikit-learn* di *Python*. Model ini akan dilatih menggunakan dataset yang telah diproses.

*Random Forest* juga akan diimplementasikan dengan cara yang sama, dan model ini akan dilatih dengan parameter yang dioptimalkan untuk mendapatkan hasil terbaik
5. Evaluasi Model : Kinerja kedua algoritma akan dievaluasi menggunakan metrik seperti *MAPE (Mean Absolute Percentage Error)*, *MSE (Mean Squared Error)* dan  $R^2$  (*R-squared* / Koefisien Determinasi). Hasil dari kedua model akan dilakukan perbandingan untuk mengetahui algoritma mana yang lebih efektif dalam konteks dataset yang digunakan.

### 1.7. Ruang Lingkup

Beberapa aspek penting termasuk dalam ruang lingkup penelitian ini yaitu :

1. Fokus Penelitian : Penelitian ini akan berfokus pada perbandingan efektivitas algoritma *Random Forest* dan *Decision Tree* dalam memprediksi hasil dari

dataset tertentu. Algoritma akan diterapkan pada dataset yang relevan dan memiliki karakteristik yang sesuai untuk analisis.

2. Jenis Data : *Dataset* yang akan dilakukan dalam penelitian ini akan mencakup data numerik yang dapat digunakan untuk pelatihan dan pengujian model. Data akan mencakup variabel yang berhubungan dengan masalah yang diteliti, seperti variabel *independen* (fitur) dan variabel *dependen* (target).
3. Batasan Waktu : Penelitian ini dilakukan dalam jangka waktu tertentu, dengan pengumpulan data dan analisis yang direncanakan dalam periode penelitian yang telah ditentukan.
4. Metodologi : Penelitian ini akan menggunakan metode kuantitatif dengan pendekatan eksperimen, yang melibatkan implementasi dan evaluasi kedua algoritma. Hasil penelitian akan dianalisis menggunakan metrik evaluasi yang relevan untuk membandingkan kinerja kedua algoritma.
5. Keterbatasan : Penelitian ini tidak akan mencakup algoritma lain di luar *Random Forest* dan *Decision Tree*, sehingga hasil yang diperoleh hanya berlaku untuk kedua algoritma tersebut. Penelitian ini memiliki batasan signifikan karena tidak mengimplementasikan proses *tuning hyperparameter*, yang berarti model beroperasi dengan pengaturan *default* dari pustaka yang digunakan. Selain itu, evaluasi model hanya mengandalkan pembagian data latih dan data uji secara sederhana tanpa penerapan teknik validasi silang (*cross-validation*), sehingga potensi *overfitting* atau *underfitting* model tidak dapat dievaluasi secara komprehensif melalui analisis kurva pembelajaran (*learning curves*) Penelitian ini juga tidak akan membahas aspek implementasi algoritma dalam konteks industri atau aplikasi praktis secara mendalam.



### 1.8. Hipotesis

Hipotesis yang diajukan dalam penelitian ini adalah sebagai berikut:

- a. Hipotesis 0 ( $H_0$ ): tidak terdapat perbedaan performa antara algoritma *random forest* dan *decision tree* dalam *GDP Deflator*.
- b. Hipotesis 1 ( $H_1$ ): terdapat perbedaan performa antara algoritma *random forest* dan *decision tree* dalam *GDP Deflator*.



## **BAB II**

### **LANDASAN TEORI**

#### **2.1. Tinjauan Pustaka**

##### **2.1.1. *OECD (Organization for Economic Cooperation and Development)***

“Ekonomi *OECD* adalah sekelompok negara maju dan berkembang yang dianggap sebagai pendorong utama pertumbuhan ekonomi dunia.”(Ahmad et al., 2023) *OECD* didirikan dengan tiga tujuan:

- a. mendorong pertumbuhan ekonomi, lapangan kerja, dan standar hidup yang berkelanjutan
- b. mendorong pertumbuhan ekonomi yang sehat
- c. berkontribusi pada perluasan perdagangan global secara multilateral yang adil bagi semua anggota.

*OECD* adalah organisasi keanggotaan yang terdiri dari 38 negara. Negara-negara ini, 33 di antaranya adalah negara maju dan 5 negara berkembang, secara kolektif menyumbang 41,1% *GDP global* dan menguasai 80% perdagangan dunia. Anggota *OECD* dari Eropa mencakup Austria, Belgia, Republik Ceko, Denmark, Estonia, Finlandia, Prancis, Jerman, Yunani, Hungaria, Islandia, Irlandia, Italia, Latvia, Lituania, Luksemburg, Belanda, Norwegia, Polandia, Portugal, Slovakia, Slovenia, Spanyol, Swedia, Swiss, dan Inggris. Indonesia telah menjadi mitra kunci *OECD* sejak 2007 melalui *Enhanced Engagement Program*. Kemitraan ini diperkuat dengan bergabungnya Indonesia ke *Framework of Cooperation Agreement* pada 2012 dan *Privileges and Immunity Agreement* pada 2013. Pada tahun 2014, Indonesia terpilih

sebagai *Co-Chair* untuk *OECD Southeast Asia Regional Program (OECD SEARP)*, dan pada 2015, kantor perwakilan *OECD* di Jakarta diresmikan. (Dewi, 2024)

### **2.1.2. Pengertian Indikator Ekonomi**

Pertumbuhan ekonomi adalah isu ekonomi yang bersifat jangka panjang dan menjadi fenomena global yang signifikan belakangan ini. Fenomena ini erat kaitannya dengan peningkatan produksi barang dan jasa dalam aktivitas ekonomi masyarakat. Dengan kata lain, pertumbuhan ekonomi dapat diartikan sebagai perkembangan satu dimensi yang diukur dari kenaikan hasil produksi dan pendapatan. (Hartati, 2021)

Berbagai indikator ekonomi makro digunakan untuk menilai dan memproyeksikan arah pertumbuhan ekonomi saat ekonomi suatu negara berkembang. Dalam penelitian ini, digunakan lima variabel utama yang memiliki korelasi kuat dengan pertumbuhan ekonomi. Variabel-variabel tersebut adalah sebagai berikut:

a. *Labour tax revenue* (Pendapatan Tenaga Kerja)

Salah satu bentuk pendapatan negara yang berasal dari kontribusi pemberi kerja dan pekerja terhadap sistem pajak adalah pendapatan pajak tenaga kerja.

b. *Life expectancy at birth* (Angka harapan hidup saat lahir)

Tingkat kesehatan dan kualitas hidup penduduk suatu negara diukur dari angka harapan hidup sejak lahir. Kualitas layanan kesehatan, pendidikan, dan infrastruktur dasar sering kali berkorelasi positif dengan angka harapan hidup yang tinggi.

c. *Nominal exchange rate* (Nilai tukar nominal)

Nilai tukar nominal memainkan peran penting dalam stabilitas ekonomi dan perdagangan internasional. Perubahan nilai tukar berdampak pada arus modal, daya saing ekspor-impor, dan nilai aset domestik.

d. *Value added* (Nilai Tambah)

Produksi ekonomi, khususnya industri dan jasa, diukur dengan nilai tambah. Ditunjukkan dengan nilai tambah yang tinggi, industri-industri ini memainkan peran besar dalam menciptakan nilai ekonomi dari bahan mentah hingga produk akhir. .

e. *GDP Deflator* (Produk Domestik Bruto (PDB))

*GDP Deflator* sangat penting untuk menganalisis pertumbuhan ekonomi riil tanpa terdistorsi oleh inflasi karena merupakan indikator yang mengukur tingkat harga barang dan jasa yang diproduksi. Oleh karena itu, *GDP Deflator* membantu mengubah Produk Domestik Bruto dari nilai nominal menjadi nilai riil.

### 2.1.3. Pengertian Machine Learning

*Machine Learning* merupakan bagian penting dari domain kecerdasan buatan dan digunakan untuk menyelesaikan berbagai masalah. Dalam *machine learning* mempelajari algoritma dan model statistik yang digunakan oleh sistem komputer untuk menyelesaikan tugas-tugas tertentu dengan menggunakan pola dan infrensi sebagai pengganti instruksi langsung. Tujuan machine learning ialah untuk mengajarkan mesin agar dapat memproses data dengan lebih efisien. *Machine Learning* juga dapat meramalkan dan memahami karakteristik objek yang tidak dikenal melalui pengidentifikasian pola dalam set. (Nurhalizah et al., 2024)

*Machine Learning* terdiri dari berbagai kategori dan jenis algoritma yang masing-masing memiliki tujuan dan fungsinya masing-masing ,salah satunya seperti berikut :

### 2.1.4. Supervised Learning

“*Supervised learning* merupakan pembelajaran yang terarah atau diawasi dengan mempelajari data *training* sebagai label. Dalam *supervised learning*

pembelajaran terarah dapat berupa klasifikasi maupun regresi.”(Septiani, 2023) yang terdiri dari beberapa algoritma diantaranya:

a. *Linear Regression*

“*Linear regression* merupakan model untuk memprediksi nilai numerik berdasarkan data historis dalam kurun waktu tertentu.”(Hendra et al., 2023)

*Linear Regression* sendiri yaitu jenis aturan *classification* dan *Regression* pada kegiatan data *mining*. teknik dalam data mining yang berperan sebagai aturan regresi. Teknik ini digunakan untuk mengidentifikasi dan mengukur hubungan antara variabel yang ingin diprediksi (variabel tidak bebas) dengan variabel-variabel lain (variabel bebas) yang mempengaruhinya.(Fitri & Riana, 2022)

b. *Logistic Regression*

*Logistic Regression* ialah analisis regresi yang digunakan khusus ketika variabel dependen yang ingin kita prediksi bersifat *biner* (memiliki dua kemungkinan hasil saja). *Logistic Regression* digunakan untuk menggambarkan data dan untuk menjelaskan hubungan antara satu variabel *biner* dependen dan satu atau lebih variabel independen *nominal*, *ordinal*, *interval* atau rasio tingkat.(Sitanggang et al., 2022)

c. *Decision Tree*

*Decision Tree* adalah metode dalam pemrosesan data yang memprediksi masa depan dengan membangun model klasifikasi atau regresi dalam bentuk struktur pohon. Model visual ini membantu kita memahami proses pengambilan keputusan secara terstruktur, bertahap, dan rasional.(Nurani et al., 2023)

d. *Random Forest*

“*Random Forest*, merupakan sebuah metode yang dikembangkan dari metode *CART (Classification and Regression Trees)*, yang juga merupakan metode atau algoritma dari teknik pohon keputusan.” (Adrian et al., 2021)

*Random Forest* merupakan perluasan dari metode *Decision Tree* yang menggunakan beberapa *Decision Tree*. Setiap *Decision Tree* telah dilatih dengan sampel dan setiap atribut didistribusikan ke pohon yang dipilih dari subset atribut secara acak. memiliki beberapa keunggulan, antara lain kemampuan untuk meningkatkan hasil akurasi pada kasus data yang hilang, kemampuan untuk mencegah anomali, dan kemampuan untuk menyimpan data secara efisien. Memiliki kemampuan seleksi fitur yang membantu mengidentifikasi dan memilih fitur-fitur paling relevan demi meningkatkan kinerja model. (Arisusanto et al., 2023)

e. *K-Nearest Neighbors (KNN)*

*K-Nearest Neighbor (KNN)* adalah algoritma *supervised learning* yang mengklasifikasikan instance baru berdasarkan kategori mayoritas dari data tetangga terdekatnya. Kelas yang paling sering muncul di antara tetangga terdekat akan menjadi hasil klasifikasi akhir. Data yang diambil adalah data yang telah dihitung rata-rata dari data awal. (Diansyah, 2022)

### 2.1.5. Pengertian *python*

*Python* adalah bahasa pemrograman tingkat tinggi yang mendukung berbagai fungsi. Bahasa ini menjalankan instruksi secara langsung (interpretatif) dengan menerapkan metode *Object-Oriented Programming* dan menggunakan semantik dinamis, yang semuanya berkontribusi pada kemudahan pembacaan sintaksnya. (Rahmadhika & Thantawi, 2021)



### 2.1.6. Pengertian Google Colab

*Google Colab* merupakan sebuah *IDE* untuk pemrograman *Python* dimana pemrosesan akan dilakukan oleh *server Google* yang memiliki perangkat keras dengan performa yang tinggi. (Guntara, 2023)

### 2.1.7. Penelitian Terkait

Untuk memperkuat landasan teori dan metodologi dalam skripsi ini, peneliti mengkaji dan mengadopsi berbagai referensi dari penelitian terdahulu yang sejalan dengan fokus penelitian. Berikut adalah beberapa penelitian yang menjadi rujukan:

**Tabel II. 1**  
**Penelitian Terkait**

| No | Judul & Peneliti                                                                                                                                           | Metode/Algoritma                               | Variabel/Indikator                                                                                            | Hasil Penelitian                                                                                                                                                |
|----|------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------|---------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | Prediksi Penyakit Hipertensi Menggunakan Metode <i>Decision Tree</i> dan <i>Random Forest</i> . (Rizky et al., 2024)                                       | <i>Decision Tree</i> dan <i>Random Forest</i>  | 14 indikator hipertensi: usia, jenis kelamin, tekanan darah, kolesterol, dan atribut lainnya dari 26.083 data | Kedua metode ( <i>Decision Tree</i> & <i>Random Forest</i> ) mencapai akurasi 100% dalam prediksi hipertensi setelah <i>hyperparameter tuning</i> dan evaluasi. |
| 2  | Perbandingan Kinerja <i>Regresi Decision Tree</i> dan <i>Regresi Linear</i> Berganda untuk Prediksi BMI pada <i>Dataset Asthma</i> . (Nurani et al., 2023) | <i>Decision Tree</i> dan <i>Regresi Linear</i> | Jenis kelamin, status merokok, status asma, SNP (data genetik), dan BMI                                       | <i>Regresi Linear</i> Berganda memiliki MAPE lebih rendah (12,76%) dibandingkan <i>Decision Tree</i> (12,79%), menunjukkan performa prediksi yang lebih baik.   |
| 3  | Komparasi Algoritma <i>Random Forest</i> Dan <i>Decision Tree</i> Untuk Memprediksi                                                                        | <i>Random Forest</i> & <i>Decision Tree</i>    | 8 atribut + 1 label pada <i>dataset immunotherapy</i> dari UCI                                                | <i>Random Forest</i> menghasilkan akurasi 85,5%, lebih tinggi dari <i>Decision Tree</i> (84,4%),                                                                |

| No | Judul & Peneliti                                                                                                                                                                                                 | Metode/Algoritma                                                        | Variabel/Indikator                                                                                              | Hasil Penelitian                                                                                                                                        |
|----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
|    | Keberhasilan <i>Immunotherapy</i> . (Pamuji et al., 2021)                                                                                                                                                        |                                                                         |                                                                                                                 | menunjukkan kinerja lebih unggul.                                                                                                                       |
| 4  | Analisa Perbandingan Model <i>Prediction</i> dalam Prediksi Harga Saham Menggunakan Metode <i>Linear Regression</i> , <i>Random Forest Regression</i> , dan <i>Multilayer Perceptron</i> . (Fitri & Riana, 2022) | <i>Linear Regression</i> , <i>Random Forest Regression</i> , <i>MLP</i> | Harga saham historis ( <i>open</i> , <i>high</i> , <i>low</i> , <i>close</i> ) dari emiten INDF, KAEF, dan TLKM | <i>Linear Regression</i> menghasilkan error terendah (RMSE 0.010–0.012) dan $R^2$ tertinggi (99,6%–99,8%), unggul dibanding <i>RFR</i> dan <i>MLP</i> . |
| 5  | Perbandingan Metode Klasifikasi <i>Random Forest</i> dan <i>SVM</i> Pada Analisis Sentimen PSBB. (Adrian et al., 2021)                                                                                           | <i>Random Forest</i> & <i>Support Vector Machine (SVM)</i>              | Tweet terkait PSBB (Pembatasan Sosial Berskala Besar) di <i>Twitter</i>                                         | <i>Random Forest</i> memiliki akurasi lebih tinggi (57,8%) dibandingkan <i>SVM</i> (55,7%), namun <i>SVM</i> lebih baik mendeteksi sentimen positif.    |


## BAB III

### METODOLOGI PENELITIAN

Penelitian ini menggunakan pendekatan kuantitatif dengan desain penelitian *eksperimental* adalah pendekatan yang paling efektif untuk mengidentifikasi hubungan sebab-akibat. Metode ini sering dianggap sebagai standar baku dalam ilmu pengetahuan karena sifatnya yang objektif dan presisi.(Yunitri, N., & Janitra, F. E., 2024)

#### 3.1. Tahapan Penelitian

Penelitian ini dilakukan secara sistematis melalui serangkaian tahapan yang terstruktur, mulai dari identifikasi masalah hingga evaluasi hasil, guna mencapai tujuan secara menyeluruh.



**Gambar III. 1**  
**Metodologi Penelitian**

Untuk mencapai tujuan penelitian, setiap langkah yang ditunjukkan dalam diagram alir ini akan diimplementasikan secara berurutan.

### **3.1.1. Identifikasi Permasalahan**

Pada tahap awal penelitian ini, sebuah masalah utama diidentifikasi: kebutuhan akan metode yang tepat untuk menganalisis indikator ekonomi yang kompleks seperti *GDP Deflator*.

### **3.1.2. Studi Literatur**

Selanjutnya, dilakukan studi literatur dan referensi dari jurnal ilmiah, buku, dan tesis terdahulu. Tujuan penelitian ini adalah untuk memahami tentang teori yang mendasari algoritma yang digunakan serta gambaran umum tentang penelitian serupa. Dengan memahami kelebihan dan kekurangan masing-masing algoritma dari penelitian sebelumnya, peneliti dapat menentukan metodologi dan teknik yang sesuai untuk penelitian ini.

### **3.1.3. Pengumpulan Data**

Data yang digunakan berasal dari platform resmi dan tepercaya, seperti *OECD Data Explorer*. Dataset ini mencakup indikator ekonomi Indonesia dari tahun 2010 hingga 2022, termasuk nilai tambah ekonomi, angka harapan hidup, pendapatan pajak tenaga kerja, dan nilai tukar nominal. Cakupan data yang lengkap dan relevan dengan tujuan penelitian karena pengumpulan data dilakukan secara sistematis.

### **3.1.4. Preprocessing Data**

Sebelum data dianalisis, tahap prapemrosesan data harus dilakukan. Hal ini melibatkan pembersihan data dari duplikasi, kesalahan penulisan, atau nilai yang tidak valid. Selain itu, nilai yang hilang ditangani melalui metode imputasi atau penghapusan, tergantung pada kondisi data.

### 3.1.5. Exploratory Data Analysis (EDA)

Tujuan dari tahap *EDA* adalah untuk mendapatkan pemahaman tentang karakteristik dasar dari data yang digunakan. Analisis statistik deskriptif dan visualisasi grafik seperti *boxplot*, *scatterplot*, *histogram*, dan *heatmap* korelasi digunakan oleh peneliti untuk mengevaluasi distribusi, *outlier*, dan hubungan antar variabel. Oleh karena itu, pola yang dapat digunakan sebagai acuan untuk modeling dan fitur yang memiliki korelasi tinggi terhadap *GDP Deflator* dapat ditemukan.

### 3.1.6. Implementasi Algoritma

Setelah memahami data secara menyeluruh, algoritma *Decision Tree* dan *Random Forest* diimplementasikan menggunakan pustaka *scikit-learn* di *Python*. Dengan menggunakan fungsi *train\_test\_split*, dataset dibagi menjadi dua bagian: 80% data pelatihan dan 20% data pengujian. Data pelatihan digunakan untuk melatih setiap algoritma, dan penyesuaian parameter dilakukan untuk mengoptimalkan kinerja model.

### 3.1.7. Hasil Evaluasi Model

Tiga metrik evaluasi utama adalah :

- a. Untuk menghitung seberapa besar persentase kesalahan, gunakan *MAPE (Mean Absolute Percentage Error)*.
- b. Untuk menentukan seberapa besar kesalahan kuadrat rata-rata dari prediksi model, gunakan *MSE (Mean Squared Error)*.
- c. *R2 (Koefisien Determinasi)* untuk mengetahui seberapa baik model menjelaskan variasi data. Hasil evaluasi kedua algoritma tersebut dibandingkan untuk menentukan model mana yang lebih unggul dalam hal akurasi dan ketahanan terhadap gangguan.

### 3.2. Instrument Penelitian

Instrumen yang digunakan dalam penelitian ini adalah:

#### 3.2.1. Perangkat Keras

Penelitian ini menggunakan perangkat keras dengan spesifikasi sebagai berikut:

|                |                                                       |
|----------------|-------------------------------------------------------|
| Processor      | AMD Athlon Silver 3050U with Radeon Graphics 2.30 GHz |
| RAM            | 8.00 GB                                               |
| Storage        | SSD 119 GB                                            |
| Sistem Operasi | Windows 11                                            |

**Tabel III. 1**  
**Perangkat Keras**

#### 3.2.2. Perangkat Lunak

Pada penelitian ini memanfaatkan berbagai perangkat lunak untuk analisis data dan pemodelan:

**Tabel III. 2**  
**Perangkat Lunak**

|                                     |                                                                                                                                                                                                                                                                     |
|-------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Bahasa Pemrograman</b>           | <i>Python 3.8</i> atau versi lebih baru                                                                                                                                                                                                                             |
| <i>Environment</i> dan <i>IDE</i>   | <i>Google Colab</i>                                                                                                                                                                                                                                                 |
| <i>Library</i> dan <i>Framework</i> | <ul style="list-style-type: none"> <li>• <i>Pandas</i> dan <i>NumPy</i> untuk manipulasi data</li> <li>• <i>Scikit-learn</i> untuk implementasi algoritma <i>machine learning</i></li> <li>• <i>Matplotlib</i> dan <i>Seaborn</i> untuk visualisasi data</li> </ul> |
| <i>Tool</i> Tambahan                | <ul style="list-style-type: none"> <li>• <i>OECD Data Explorer</i> untuk pengambilan data</li> </ul>                                                                                                                                                                |

### 3.3. Metode Pengumpulan Data, Populasi, dan Sample Penelitian

#### 3.3.1. Metode Pengumpulan Data

Penelitian ini memanfaatkan data sekunder yang diperoleh dari *OECD Data Explorer*, sebuah sumber tepercaya. Pengumpulan data dilakukan melalui:



- a. Pengambilan Data: Data ekonomi spesifik untuk Indonesia diperoleh dengan mengakses platform *OECD Data Explorer*.
- b. Pengunduhan Data: Data yang relevan kemudian diunduh dalam format yang mudah diolah, seperti *CSV*, *Excel*, atau *JSON*.
- c. Validasi Data: Setelah diunduh, kelengkapan dan keakuratan data diverifikasi untuk memastikan kualitasnya sebelum analisis lebih lanjut.

### 3.3.2. Populasi Penelitian

Populasi penelitian ini adalah seluruh data ekonomi Indonesia yang tersedia di *OECD Data Explorer*, terutama *GDP Deflator* dan indikator ekonomi terkait, dari semua periode yang tercakup dalam platform tersebut.

### 3.3.3. Sampel Penelitian

Sampel penelitian ini fokus terutama *GDP Deflator* dalam indikator ekonomi tertentu dari periode 2010 hingga 2022. Pemilihan periode ini didasarkan pada tiga pertimbangan utama: ketersediaan data yang lengkap dan konsisten, durasi waktu yang memadai untuk mengidentifikasi pola serta tren, dan relevansinya dengan kondisi ekonomi terkini. Data tersebut selanjutnya akan dibagi menjadi dua set:

- a. Data *training*: Akan menggunakan 80% dari total data set.
- b. Data *testing*: Akan menggunakan 20% dari total data set.

## 3.4. Metode Analisis Data

### 3.4.1. Preprocessing Data

Pra-pemrosesan data adalah langkah krusial untuk memastikan *dataset* yang optimal sebelum pemodelan. Proses ini meliputi beberapa tahapan:

- a. Penanganan *Missing Values*: Fungsi `df_pivot.isnull().sum()` telah digunakan untuk memeriksa setiap kolom, dan hasilnya menunjukkan bahwa tidak ada nilai *NaN* atau data yang hilang setelah proses pembersihan.
- b. Deteksi dan Penanganan *Outlier*: Nilai ekstrem (*outlier*) akan diidentifikasi dan ditangani menggunakan metode IQR (*Interquartile Range*) atau Z-score untuk menjaga kualitas data.

### 3.4.2. Eksplorasi Data Analysis (EDA)

Analisis eksplorasi data (EDA) dilakukan sebagai langkah awal untuk memahami karakteristik dan pola yang terkandung dalam *dataset* sebelum proses pemodelan. Tahapan EDA ini mencakup:

- a. Analisis Statistik Deskriptif: Menghitung dan menyajikan statistik ringkasan seperti *mean*, *median*, dan *standar deviasi* untuk setiap variabel dalam data. Hal ini memberikan gambaran umum tentang pusat data, penyebaran, dan bentuk distribusinya.
- b. Visualisasi Distribusi Data: Menggunakan histogram untuk menampilkan frekuensi distribusi data dan boxplot untuk mengidentifikasi potensi *outlier* serta kuartil data. Visualisasi ini membantu memahami bentuk sebaran data.
- c. Analisis Korelasi: Memeriksa hubungan linier antara *GDP Deflator* dan variabel ekonomi lainnya. Ini akan dilakukan dengan membuat matriks korelasi dan memvisualisasikannya menggunakan heatmap untuk melihat kekuatan dan arah hubungan antar variabel secara cepat.

### 3.4.3. Implementasi Algoritma Machine Learning

Kedua algoritma diimplementasikan dengan pendekatan berikut:

**Tabel III. 3**  
**Implementasi**

|                      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|----------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Decision Tree</b> | <ul style="list-style-type: none"> <li>Implementasi model Decision Tree dilakukan dengan membatasi kedalaman pohon pada level 3 (<math>max\_depth=3</math>) dan menggunakan <math>random\_state=42</math>. Pembatasan ini bertujuan ganda: untuk meminimalisir risiko <i>overfitting</i> sekaligus memastikan model tetap mudah untuk diinterpretasikan.</li> <li><i>Dataset</i> akan dibagi menjadi dua bagian: data <i>training</i> dan data <i>testing</i>, dengan proporsi 80:20</li> </ul>                   |
| <b>Random Forest</b> | <ul style="list-style-type: none"> <li>model <i>Random Forest</i> diimplementasikan melalui pustaka <i>scikit-learn</i>. Konfigurasi <math>n\_estimators=100</math> dan <math>random\_state=42</math> diterapkan untuk menjamin konsistensi hasil. Proses selanjutnya melibatkan pelatihan model dengan <i>training set</i>, diikuti dengan prediksi pada <i>test set</i>.</li> <li><i>Dataset</i> akan dibagi menjadi dua bagian: data <i>training</i> dan data <i>testing</i>, dengan proporsi 80:20</li> </ul> |

### 3.4.4. Evaluasi Model

Kinerja kedua algoritma akan diukur dan dibandingkan berdasarkan metrik evaluasi berikut:

- Mean Absolute Percentage Error (MAPE)*: mengukur rata-rata persentase kesalahan prediksi
- Mean Squared Error (MSE)*: mengukur rata-rata kuadrat selisih antara nilai prediksi dan nilai sebenarnya
- Coefficient of Determination ( $R^2$ )*: mengukur proporsi varians dalam variabel dependen yang dapat diprediksi dari variabel independen

### 3.4.5. Analisis Feature Importance

Untuk mengungkap variabel-variabel ekonomi yang paling dominan dalam memengaruhi *GDP Deflator*, analisis *feature importance* akan dilaksanakan


- a) Visualisasi *feature importance* menggunakan bar chart
- b) Analisis perbandingan *feature importance Random Forest*

### 3.4.6. Pengujian Hipotesis

Pengujian hipotesis penelitian dilakukan dengan membandingkan:

- a) Performa kedua algoritma berdasarkan metrik evaluasi
- b) Kemudahan interpretasi model dari kedua algoritma

Hasil pengujian ini akan digunakan untuk menjawab rumusan masalah dan memverifikasi hipotesis yang telah diajukan di Bab I.



## BAB IV

### HASIL DAN PEMBAHASAN

Bab ini memaparkan hasil analisis perbandingan kinerja algoritma *Random Forest* dan *Decision Tree* dalam mengidentifikasi pola *GDP Deflator* di Indonesia, menggunakan variabel-variabel ekonomi yang relevan. Selain itu, bab ini juga membahas bagaimana pentingnya variabel (*variable importance*) memengaruhi hasil, serta menentukan algoritma mana yang paling optimal untuk tujuan ini.

#### 4.1. Deskripsi *Dataset*

*Dataset* yang dimanfaatkan dalam penelitian ini bersumber dari *OECD Data Explorer*, mencakup berbagai indikator ekonomi Indonesia dari tahun 2010 hingga 2022. Fokus utama penelitian ini adalah *GDP Deflator* sebagai variabel target. Selain itu, dataset ini juga menyertakan sejumlah variabel *independen* (fitur) yang telah diidentifikasi memiliki korelasi kuat dengan indikator ekonomi, yaitu :

- a) Pendapatan Pajak Tenaga Kerja (*Labour tax revenue*)
- b) Angka Harapan Hidup Saat Lahir (*Life expectancy at birth*)
- c) Nilai Tukar Nominal (*Nominal exchange rate*)
- d) Nilai Tambah Ekonomi (*Value added*).

Secara keseluruhan, *dataset* ini terdiri dari data selama periode 13 tahun (2010-2022). Struktur *dataset* dapat dilihat sebagai berikut:


|    | Country_Region | Year | GDP deflator | Labour tax revenue | Life expectancy at birth | Nominal exchange rate | Value added |
|----|----------------|------|--------------|--------------------|--------------------------|-----------------------|-------------|
| 0  | IDN            | 2010 | 69.43        | 3.990              | 68.36                    | 9090.43               | 33.333333   |
| 1  | IDN            | 2011 | 74.62        | 3.895              | 68.63                    | 8770.43               | 33.333333   |
| 2  | IDN            | 2012 | 77.42        | 4.175              | 68.86                    | 9386.63               | 33.336667   |
| 3  | IDN            | 2013 | 81.26        | 4.290              | 69.06                    | 10461.24              | 33.333333   |
| 4  | IDN            | 2014 | 85.69        | 4.725              | 69.29                    | 11865.21              | 33.333333   |
| 5  | IDN            | 2015 | 89.10        | 5.030              | 69.52                    | 13389.41              | 33.333333   |
| 6  | IDN            | 2016 | 91.27        | 8.630              | 69.73                    | 13308.33              | 33.333333   |
| 7  | IDN            | 2017 | 95.19        | 6.470              | 69.95                    | 13380.83              | 33.333333   |
| 8  | IDN            | 2018 | 98.82        | 6.390              | 70.08                    | 14236.94              | 33.333333   |
| 9  | IDN            | 2019 | 100.40       | 7.060              | 70.35                    | 14147.67              | 33.333333   |
| 10 | IDN            | 2020 | 100.00       | 8.330              | 68.82                    | 14582.20              | 33.336667   |
| 11 | IDN            | 2021 | 106.00       | 7.320              | 67.45                    | 14308.14              | 33.333333   |
| 12 | IDN            | 2022 | 116.15       | 8.880              | 70.92                    | 14849.85              | 33.336667   |

**Gambar IV. 1**  
***Dataset***

#### **4.2. Hasil *Pra-Pemrosesan* Data**

Sebelum data dapat digunakan untuk membangun model, serangkaian tahapan *pra-pemrosesan* diterapkan. Tujuannya adalah untuk memastikan data bersih, konsisten, dan siap untuk analisis prediktif. Langkah-langkah yang dilakukan meliputi:

##### **4.2.1. *Missing Value***



|                          |   |
|--------------------------|---|
|                          | 0 |
| Year                     | 0 |
| GDP deflator             | 0 |
| Labour tax revenue       | 0 |
| Life expectancy at birth | 0 |
| Nominal exchange rate    | 0 |
| Value added              | 0 |


**Gambar IV. 2**  
***Missing Value***



Data sudah bersih dari nilai yang hilang. Fungsi `df_pivot.isnull().sum()` telah digunakan untuk memeriksa setiap kolom, dan hasilnya menunjukkan bahwa tidak ada nilai *NaN* atau data yang hilang setelah proses pembersihan.

#### 4.2.2. Hasil Duplikat

Hasil pemeriksaan nilai duplikat menunjukkan bahwa tidak ada nilai yang duplikat dalam setiap kolom dari *DataFrame* `df_pivot`. Setiap kolom, yang sebelumnya dianggap sebagai baris setelah transposisi, memiliki nilai-nilai unik tanpa pengulangan. Dengan semua nilai di output sebagai *False*, ini menandakan bahwa setiap kolom memiliki nilai yang berbeda, sehingga data dalam kolom-kolom tersebut bebas dari duplikasi.



```
0    False
1    False
2    False
3    False
4    False
5    False
6    False
7    False
8    False
9    False
10   False
11   False
12   False
dtype: bool
```

**Gambar IV. 3**  
**Hasil Duplikat**


#### 4.2.3. Hasil *Outlier* dan Penanganan *Outlier*

```
Number of Outlier values with respect to features:

GDP deflator : 0
Labour tax revenue : 0
Life expectancy at birth : 0
Nominal exchange rate : 0
Value added : 3
```

**Gambar IV. 4**  
**Hasil *Outlier***

Hasil analisis *outlier* menunjukkan bahwa sebagian besar variabel, seperti *GDP deflator*, *Labour tax revenue*, *Life expectancy at birth*, dan *Nominal exchange rate*, tidak memiliki nilai yang menyimpang atau anomali. Namun, variabel *Value added* memiliki tiga nilai *outlier* yang signifikan, yang berarti data-data tersebut sangat berbeda dari mayoritas nilai dalam variabel tersebut. Untuk menangani anomali ini, ada beberapa metode yang bisa diterapkan, yaitu dengan menghapus nilai *outlier*, melakukan transformasi data agar nilainya tidak terlalu ekstrem, atau mempertahankan data tersebut jika secara kontekstual dianggap valid dan penting.



```
Jumlah outlier sesudah penanganan:

GDP deflator : 0
Labour tax revenue : 0
Life expectancy at birth : 0
Nominal exchange rate : 0
Value added : 0
```

**Gambar IV. 5**  
**Setelah Penanganan *Outlier***

bahwa setelah penerapan fungsi penanganan *outlier*, tidak ada lagi nilai *outlier* yang terdeteksi di semua fitur dataset (semua menunjukkan 0 *outlier*). Ini berarti metode *Z-score* dengan threshold 3 yang digunakan telah berhasil membersihkan data dari nilai-nilai ekstrem, termasuk pada fitur "*Value Added*" yang sebelumnya memiliki *outlier* pada *boxplot*.

Menggunakan *z-score* dalam menangani *outlier* memiliki beberapa alasan:


- Normalisasi:** *Z-score* mengukur seberapa jauh sebuah nilai dari rata-rata dalam satuan deviasi standar, sehingga memudahkan perbandingan antar nilai.
- Deteksi yang Efisien:** *Z-score* memudahkan identifikasi *outlier*, dengan batas umumnya di luar -3 dan 3, menunjukkan nilai yang ekstrem.

- c. Distribusi Normal: Cocok untuk data yang berdistribusi normal, *z-score* membantu mengurangi pengaruh *outlier* pada analisis statistik lebih lanjut.
- d. Fleksibilitas: Dapat digunakan dalam berbagai teknik analisis dan model *machine learning*.

Sebelum implementasi model guna menjamin kualitas dan kecocokan data. Setelah pemeriksaan menyeluruh. Kondisi ini memungkinkan penyajian langsung data dan hasil analisis korelasi, tanpa modifikasi kompleks yang biasanya diperlukan untuk mengatasi kekosongan data.


#### 4.2.4. Hasil *Exploratory Data Analysis* (EDA)

Setelah tahap *pra-pemrosesan*, *Exploratory Data Analysis* (EDA) dilakukan untuk mendapatkan pemahaman mendalam mengenai karakteristik data. EDA mencakup visualisasi distribusi setiap variabel, serta pemeriksaan matriks korelasi antar variabel.



**Gambar IV. 6**  
**Distribusi Data**

Sebelum melakukan implementasi model, dilakukan analisis distribusi data untuk memahami karakteristik setiap variabel dalam dataset. Berdasarkan visualisasi distribusi yang disajikan, terlihat bahwa dataset memiliki variasi pola distribusi yang beragam antar variabel.



Gambar IV. 7  
Korelasi

#### 4.3. Implementasi Algoritma

Setelah memahami data secara menyeluruh, algoritma *Decision Tree* dan *Random Forest* diimplementasikan menggunakan pustaka *scikit-learn* di *Python*. *Dataset* dibagi menjadi 80% data pelatihan dan 20% data pengujian menggunakan fungsi *train\_test\_split*. Data pelatihan digunakan untuk melatih setiap algoritma, dan penyesuaian parameter dilakukan untuk mengoptimalkan kinerja model.

#### 4.3.1. Implementasi *Random Forest*

Algoritma *Random Forest* diimplementasikan sebagai kumpulan (*ensemble*) dari beberapa *Decision Tree*. Parameter penting yang diatur dalam model *Random Forest* meliputi:

- a. *n\_estimators*: Jumlah pohon keputusan dalam hutan.
- b. *max\_depth*: Kedalaman maksimum setiap pohon.
- c. *min\_samples\_split*: Jumlah minimum sampel yang diperlukan untuk memecah sebuah *node*.
- d. *min\_samples\_leaf*: Jumlah minimum sampel yang diperlukan pada *leaf node*.
- e. *max\_features*: Jumlah fitur yang dipertimbangkan untuk setiap *split*.

#### 4.3.2. Implementasi *Decision Tree*

Model *Decision Tree* dilatih menggunakan data latih yang telah diproses. Parameter kunci yang digunakan dalam model *Decision Tree* meliputi:


- *max\_depth*: Mengontrol kedalaman maksimum pohon untuk menghindari *overfitting*.
- *min\_samples\_split*: Jumlah minimum sampel yang diperlukan untuk memecah sebuah *node*.
- *min\_samples\_leaf*: Jumlah minimum sampel yang diperlukan pada *leaf node*.

#### 4.4. Hasil Evaluasi Model

Kinerja kedua algoritma dievaluasi menggunakan metrik yang relevan untuk masalah regresi, yaitu *Mean Absolute Percentage Error (MAPE)*, *Mean Squared Error (MSE)*, dan *Coefficient of Determination ( $R^2$ )*.

#### 4.4.1. Perbandingan Kinerja Algoritma

Berikut adalah grafik yang menyajikan hasil perbandingan kinerja antara algoritma *Random Forest* dan *Decision Tree* berdasarkan metrik evaluasi yang digunakan:




**Gambar IV. 8**  
**Perbandingan Algoritma**

Berdasarkan perbandingan kinerja model, *Decision Tree* menunjukkan performa yang lebih unggul dibandingkan *Random Forest* pada metrik *Mean Squared Error (MSE)*, *R² Score*, dan *Mean Absolute Percentage Error (MAPE)*. *Decision Tree* mencatat *MSE* yang lebih rendah (sekitar 29% vs 52%), *R² Score* yang lebih tinggi (sekitar 0.89 vs 0.88), dan *MAPE* yang lebih rendah (sekitar 5.5% vs 6.9%), secara konsisten mengindikasikan akurasi prediksi yang lebih baik dan kemampuan penjelasan varian data yang superior dalam konteks dataset yang dianalisis.

#### 4.4.2. Hasil *Feature Importance*

Untuk mencapai pemahaman yang komprehensif tentang arsitektur dan kinerja model, tidak cukup hanya mengevaluasi metrik akurasi; peneliti juga perlu menguraikan bagaimana setiap variabel berkontribusi. Dengan demikian, berikut adalah visualisasi *feature importance* yang dihasilkan :






**Gambar IV. 9**  
***Feature Importance***

Dari grafik diatas, jelas terlihat bahwa pendapatan pajak tenaga kerja dan nilai tukar nominal adalah faktor-faktor paling berpengaruh dalam memprediksi variabel target. Angka harapan hidup saat lahir juga berperan, meskipun tidak sekuat dua faktor pertama, sementara nilai tambah terbukti memiliki kontribusi yang sangat kecil.

#### **4.4.3. Hasil Visualisasi *Decision Tree***

Untuk memahami bagaimana model peneliti mengambil keputusan dan fitur apa saja yang paling berperan, berikut adalah visualisasi pohon keputusan (*Decision Tree*) yang dihasilkan.



**Gambar IV. 10**  
**Visualisasi *Decision Tree***

Visualisasi *Decision Tree* dengan jelas menunjukkan bahwa '*Labour tax revenue*' adalah fitur yang paling penting. Posisinya di node akar menandakan bahwa ia adalah fitur pertama dan paling kuat yang digunakan oleh model untuk membagi data dan mulai membentuk prediksi. Ini adalah pembagian yang memberikan dampak paling besar pada seluruh dataset dalam upaya untuk memprediksi nilai target.

#### 4.5. Pembahasan

Pada bagian ini, peneliti akan membandingkan dua algoritma *Random Forest* dan *Decision Tree* keduanya penting dalam *machine learning*. Fokus utamanya adalah kinerja *Random Forest* dan *Decision Tree*, menggunakan metrik seperti : *Mean Squared Error* (MSE), *Mean Absolute Percentage Error* (MAPE), dan  $R^2$  Score.

#### 4.5.1. Perbandingan Kinerja Random Forest dan Decision Tree

**Tabel IV. 1**  
**Perbandingan Hasil Indonesia**

| Random Forest              |       | Decision Tree              |       |
|----------------------------|-------|----------------------------|-------|
| <i>MSE</i>                 | 52%   | <i>MSE</i>                 | 29%   |
| <i>MAPE</i>                | 6.9%  | <i>MAPE</i>                | 5.5%  |
| <i>R<sup>2</sup> SCORE</i> | 0.80% | <i>R<sup>2</sup> SCORE</i> | 0.89% |

Tabel di atas adalah hasil perbandingan kinerja menunjukkan bahwa *Decision Tree* mengungguli *Random Forest* di seluruh metrik evaluasi. *Decision Tree* mencatat *Mean Squared Error* (MSE) yang lebih rendah (sekitar 29 dibandingkan 52), *R<sup>2</sup> Score* yang lebih tinggi (sekitar 0.89 dibandingkan 0.80), dan *Mean Absolute Percentage Error* (MAPE) yang lebih rendah (sekitar 5.5% dibandingkan 6.9%). Hal ini secara konsisten mengindikasikan bahwa *Decision Tree* memberikan akurasi prediksi yang lebih baik, kesalahan yang lebih rendah, dan kemampuan penjelasan varian data yang superior dalam konteks dataset yang dianalisis. Dengan demikian, pada implementasi dasar, algoritma *Decision Tree* dengan parameter *default* lebih efektif dalam menangkap pola data dibandingkan *Random Forest* untuk dataset variabel yang digunakan.

#### 4.5.2. Pengaruh Variabel *Importance*

Berdasarkan diagram batang pada Gambar IV.9 *Feature Importance*, berikut adalah analisis pengaruh setiap variabel (pentingnya fitur) terhadap variabel target (yang tidak disebutkan secara *eksplisit*, tetapi tersirat sebagai apa yang coba diprediksi oleh model):

- a) *Penerimaan pajak tenaga kerja (Labour tax revenue)*: Variabel ini memiliki skor kepentingan fitur tertinggi, yaitu 0.40. Ini menunjukkan bahwa "Penerimaan pajak tenaga kerja" adalah variabel yang paling berpengaruh dalam model *Random Forest*. Perubahan atau variasi dalam penerimaan pajak tenaga kerja kemungkinan besar akan memiliki dampak paling signifikan pada hasil yang diprediksi.
- b) *Nilai tukar nominal (Nominal exchange rate)*: Dengan skor kepentingan fitur sebesar 0.38, "Nilai tukar nominal" adalah variabel terpenting kedua. Variabel ini memiliki pengaruh substansial terhadap prediksi model, hampir sama dengan penerimaan pajak tenaga kerja.
- c) *Angka harapan hidup saat lahir (Life expectancy at birth)*: Variabel ini memiliki skor kepentingan fitur sebesar 0.20. Meskipun masih berkontribusi pada prediksi model, pengaruhnya jauh lebih kecil dibandingkan dengan penerimaan pajak tenaga kerja dan nilai tukar nominal.
- d) *Nilai tambah (Value added)*: Variabel ini memiliki skor kepentingan fitur terendah, yaitu 0.02. Ini menunjukkan bahwa "Nilai tambah" memiliki pengaruh yang sangat kecil terhadap prediksi model dibandingkan dengan variabel lainnya. Kontribusinya dalam menjelaskan variansi pada variabel target sangat minim.


#### 4.5.3. Stabilitas Akurasi

Evaluasi akurasi kedua algoritma menunjukkan hasil yang menarik dalam konteks implementasi dasar tanpa optimasi *hyperparameter*. *Decision Tree* menunjukkan tingkat akurasi yang lebih tinggi dengan  $R^2$  score sebesar 0.89 % dibandingkan *Random Forest* yang mencapai 0.80 %. Dari segi stabilitas *error*, *Decision Tree* juga menunjukkan konsistensi yang lebih baik dengan *MSE* sebesar 29%

dan *MAPE* sebesar 5.5%, sedangkan *Random Forest* mencatat *MSE* sebesar 52% dan *MAPE* sebesar 6.9%. Meskipun secara teoritis *Random Forest* dirancang untuk memberikan stabilitas yang lebih baik melalui mekanisme *ensemble* yang mengurangi *overfitting*, hasil pada implementasi awal ini menunjukkan bahwa *Decision Tree* mampu menangkap pola data ekonomi Indonesia dengan lebih efektif.

#### 4.5.4. Hasil Prediksi *GDP Deflator*

Bagian berikut menjelaskan hasil penelitian yang bertujuan untuk menguji dan membandingkan efektivitas dua algoritma *machine learning*, yaitu *Random Forest* dan *Decision Tree*, dalam memprediksi tren *GDP Deflator* Indonesia hingga tahun 2023.



**Gambar IV. 11**  
**Hasil Prediksi *GDP Deflator***

Berdasarkan hasil visualisasi, terlihat bahwa model *Decision Tree* mampu mengikuti tren kenaikan *GDP Deflator* yang stabil hingga mencapai puncaknya pada tahun 2022, dan mempertahankan prediksi nilai tersebut pada tahun 2023. Sebaliknya,

model *Random Forest* memprediksi adanya penurunan moderat di tahun 2023, meskipun nilainya masih tergolong tinggi. Perbedaan hasil ini mengindikasikan perbedaan fundamental dalam pendekatan kedua algoritma terhadap peramalan tren data ekonomi.

a. Prediksi *GDP Deflator* 2023 (*Random Forest*): 106.77

b. Prediksi *GDP Deflator* 2023 (*Decision Tree*): 116.15





## BAB V

### PENUTUP

#### 5.1. Kesimpulan

Berdasarkan analisis dan pembahasan yang telah dilakukan, beberapa kesimpulan dapat ditarik mengenai perbandingan kinerja algoritma *Random Forest* dan *Decision Tree* dalam menganalisis *GDP Deflator* Indonesia:

- a. Perbandingan Kinerja Algoritma: *Decision Tree* menunjukkan kinerja yang lebih baik dibandingkan dengan *Random Forest* dalam analisis *GDP Deflator* Indonesia. Hal ini didasarkan pada metrik evaluasi seperti *Mean Squared Error (MSE)*, *R<sup>2</sup> Score*, dan *Mean Absolute Percentage Error (MAPE)*. *Decision Tree* mencatatkan MSE yang lebih rendah (sekitar 36), *R<sup>2</sup> Score* yang lebih tinggi (sekitar 0.89), dan *MAPE* yang lebih rendah (sekitar 5.2%) dibandingkan *Random Forest* yang memiliki MSE sekitar 52, *R<sup>2</sup> Score* sekitar 0.84, dan *MAPE* sekitar 5.8%. Ini menunjukkan bahwa *Decision Tree* memiliki akurasi yang lebih baik, kesalahan yang lebih rendah, dan kemampuan superior dalam menjelaskan varian data pada dataset yang dianalisis.
- b. Variabel Penting (*Importance*) dari *Random Forest*: Berdasarkan analisis *feature importance* dari algoritma *Random Forest*, "Penerimaan Pajak Tenaga Kerja" (*Labour tax revenue*) adalah variabel paling berpengaruh terhadap *GDP Deflator* dengan skor 0.40. Diikuti oleh "Nilai Tukar Nominal" (*Nominal exchange rate*) dengan skor 0.37, menjadikannya variabel terpenting kedua. "Angka Harapan Hidup Saat Lahir" (*Life expectancy at birth*) juga memberikan kontribusi (0.22), namun "Nilai Tambah" (*Value added*) hanya memiliki kontribusi yang sangat kecil (0.02). Visualisasi *Decision Tree* juga mengindikasikan bahwa '*Labour tax*

*revenue'* merupakan fitur paling signifikan, sebagai *node* akar yang pertama kali digunakan model untuk membagi data dan membentuk prediksi.

- c. Algoritma Optimal: Dalam implementasi dasar tanpa optimasi *hyperparameter*, algoritma *Decision Tree* memberikan performa dan stabilitas analisis yang lebih baik untuk *GDP Deflator* Indonesia pada dataset periode 2010-2022. Meskipun *Random Forest* secara teoritis dirancang untuk memberikan stabilitas yang lebih baik melalui mekanisme *ensemble*, hasil awal menunjukkan bahwa *Decision Tree* lebih efektif dalam menangkap pola data ekonomi Indonesia. Stabilitas prediksi *Decision Tree* terlihat dari konsistensi metrik evaluasi yang unggul di semua aspek pengukuran.
- d. Perbandingan hasil prediksi, model *Decision Tree* menunjukkan nilai *GDP Deflator* yang lebih tinggi (116,15) dan cenderung stabil mengikuti tren historis, sementara model *Random Forest* menghasilkan prediksi yang lebih moderat (106,77). Perbedaan ini menunjukkan bahwa setiap algoritma memiliki pendekatan unik dalam memproses data dan menghasilkan nilai yang berbeda.

## 5.2. Saran

Berdasarkan temuan di atas, beberapa saran dapat diberikan untuk penelitian mendatang:

- a. Optimasi model *machine learning* : Disarankan untuk melakukan optimasi *cross-validation*, *learning curves*, *hyperparameter* tuning yang lebih mendalam untuk kedua algoritma (*Random Forest* dan *Decision Tree*). Hal ini bertujuan untuk menemukan konfigurasi parameter yang paling optimal, yang berpotensi meningkatkan kinerja model secara keseluruhan, terutama untuk *Random Forest*.

- b. Penambahan variabel ekonomi : Penelitian selanjutnya dapat mempertimbangkan untuk memasukkan variabel ekonomi makro tambahan yang relevan, seperti real *GDP* Percapita, *Net migration*, tingkat investasi, atau konsumsi rumah tangga. Tujuannya adalah untuk menguji pengaruhnya terhadap *GDP Deflator* dan melihat bagaimana algoritma merespons kompleksitas data yang lebih besar.
- c. Penggunaan Algoritma *Machine Learning* Lain: Selain *Random Forest* dan *Decision Tree*, algoritma *machine learning* lainnya seperti *Gradient Boosting Machines* (GBM), *XGBoost*, atau *Neural Networks* dapat diimplementasikan dan dibandingkan kinerjanya. Ini akan memberikan wawasan lebih lanjut mengenai model prediksi terbaik untuk *GDP Deflator*.
- d. Analisis Data Deret Waktu Spesifik: Mengingat sifat *GDP Deflator* sebagai data deret waktu, eksplorasi metode analisis deret waktu yang lebih spesifik seperti *ARIMA*, *Prophet*, atau *LSTM* dapat dilakukan. Pendekatan ini dapat menangani karakteristik temporal data dengan lebih efektif dan hasilnya dapat dibandingkan dengan metode *machine learning* yang sudah digunakan.
- e. Validasi Eksternal Model: Untuk memastikan kemampuan generalisasi model, validasi eksternal dapat dilakukan dengan menggunakan dataset dari negara lain atau periode waktu yang berbeda. Hal ini akan menguji ketahanan dan akurasi model yang telah dikembangkan di luar konteks data penelitian saat ini.

## DAFTAR PUSTAKA

- Aditya Arisusanto, N. S. (2023). Jurnal Teknologi Ilmu Komputer. *Analisa Klasifikasi Data Harga Handphone Menggunakan Algoritma Random Forest Dengan Optimize Parameter Grid.*
- Alfida Tegar Nurani, A. S. (2023). Jurnal Sains dan Edukasi Sains. *Perbandingan Kinerja Regresi Decision Tree dan Regresi Linear Berganda untuk Prediksi BMI pada Dataset Asthma.*
- Angeline Septhiani, H. (2023). Jurnal Sains Komputer & Informatika (J-SAKTI). *Analisis Perbandingan Algoritma Supervised Learning untuk Prediksi Kasus Covid-19 di Jakarta.*
- Brama Hendra Mahendra, L. C. (2023). Jurnal Ilmiah KOMPUTASI. *Analisis Perbandingan Prediksi Harga Saham Menggunakan Algoritma Artificial Neural Network dan Linear Regression.*
- Delima Sitanggang, N. V. (2022). Jurnal TEKINKOM. *IMPLEMENTASI DATA MINING UNTUK MEMPREDIKSI PENYAKIT JANTUNG MENGGUNAKAN METODE K-NEAREST NEIGHBOR DAN LOGISTIC REGRESSION.*
- Dewi, A. F. (2024). *Bunga Rampai Mengkaji Akses Indonesia Menuju Organisation for Economic Co-operation and Development (OECD) dalam Perspektif Masyarakat Sipil. International NGO Forum on Indonesian Development (INFID) .*
- Diansyah, S. (2022). Jurnal Sistim Informasi dan Teknologi. *Klasifikasi Tingkat Kepuasan Pengguna dengan Menggunakan Metode K-Nearest Neighbour (KNN).*
- Evita Fitri, D. R. (2022). METHOMIKA : Jurnal Manajemen Informatika & Komputerisasi Akuntansi. *ANALISA PERBANDINGAN MODEL PREDICTION DALAM PREDIKSI HARGA SAHAM MENGGUNAKAN METODE LINEAR REGRESSION, RANDOM FOREST REGRESSION DAN MULTILAYER PERCEPTRON.*
- Fandi Yulian Pamuji, V. P. (2021). Jurnal Teknologi dan Manajemen Informatika. *Komparasi Algoritma Random Forest Dan Decision Tree Untuk Memprediksi Keberhasilan Immunotherapy.*
- Fitria Endah Janitra, C. Y. (2024). METODE PENELITIAN EKSPERIMENTAL. *Jurnal Kesehatan STIKES Bethesda Yakkum Yogyakarta.*

- Guntara, R. G. (2023). Jurnal Teknologi Dan Sistem Informasi Bisnis. *Pemanfaatan Google Colab Untuk Aplikasi Pendeteksian Masker Wajah Menggunakan Algoritma Deep Learning YOLOv7.*
- Hartati, Y. S. (2021). JURNAL EKONOMI BISNIS : Sekolah Tinggi Ilmu Port Numbay Jayapura. *ANALISIS PERTUMBUHAN EKONOMI INKLUSIF DI INDONESIA.*
- M. Fahrul Rizki Aditya, N. L. (2024). Prediksi Penyakit Hipertensi Menggunakan metode Decision Tree dan Radom Forest. *Jurnal Ilmiah KOMPUTASI.*
- M. R. Adrian, M. P. (2021). Perbandingan Metode Klasifikasi Random Forest dan SVM Pada Analisi Sentimen PSBB. *JURNAL INFORMATIKA UPGRIS.*
- Maaz Ahmad, Z. K. (2023). Teknologi & Inovasi Lingkungan. *Apakah mencapai kelestarian lingkungan bergantung pada teknologi komunikasi informasi dan globalisasi? Bukti-bukti dari negara-negara OECD terpilih.*
- Muhammad Karunia Rahmadhika, A. M. (2021). Jurnal IKRA-ITH Informatika. *Rancang Bangun Aplikasi Face Recognition Pada Pendekatan CRM Menggunakan Opencv Dan Algoritma Haarcascade.*
- Nenny Hendajany, R. W. (2020). JURNAL EKONOMI DAN BISNIS. *Prediksi indikator makro ekonomi Indonesia dengan model vector autoregressive periode 2019-2023.*
- Ria Suci Nurhalizah, R. A. (2024). Jurnal Ilmu Komputer dan Informatika (JIKI). *Analisis Supervised dan Unsupervised Learning pada Machine Learning: Systematic Literature Review.*
- Rian Kurniawan, Y. M. (2023). JITET (Jurnal Informatika dan Teknik Elektro Terapan). *IMPLEMENTASI ARSITEKTUR XCEPTION PADA MODEL MACHINE LEARNING KLASIFIKASI SAMPAH ANORGANIK.*
- Rizky Ramadhani. P, N. H. (2024). Mutiara : Jurnal Penelitian dan Karya Ilmiah. *Perekonomian Indonesia Khususnya Pada Tingkat Makro.*

## DAFTAR RIWAYAT HIDUP

### I. Biodata Mahasiswa

NIM : 17210565  
Nama Lengkap : Sechan Aryatama  
Tempat/ Tanggal Lahir : Jakarta, 11 Oktober 2002  
Alamat Lengkap : Jl.Raya Jatibening 2 No 31 RT.01 RW.02, Kelurahan  
Jatibening Baru, Kecamatan Pondok Gede, Kota  
Bekasi. Kode Pos 17412

### II. Pendidikan

#### a. Formal

1. SD Negeri Jatibening Baru III, lulus tahun 2014
2. MTs Negeri 21 Jakarta, lulus tahun 2017
3. MA Negeri 18 Jakarta, lulus tahun 2020

### III. Riwayat Pengalaman berorganisasi / pekerjaan

1. Magang di PT Bangun Kreatif Abadi Sebagai UI/UX (11 September – 11 Desember 2024)

Jakarta, 03 Juli 2025



Sechan Aryatama



## SURAT PERNYATAAN KEBENARAN/KEABSAHAN DATA HASIL RISET UNTUK KARYA ILMIAH

Yang bertanda tangan di bawah ini, saya :

Nama : Sechan Aryatama  
 NIM : 17210565  
 Jenjang : Sarjana(S1)  
 Program Studi : Teknologi Informasi  
 Fakultas : Teknik dan Informatika  
 Perguruan Tinggi : Universitas Bina Sarana Informatika

Dengan ini menyatakan bahwa data atau informasi yang saya gunakan dalam penulisan karya ilmiah dengan judul “**Analisis Perbandingan Performa Algoritma *Random Forest* dan *Decision Tree* Dalam Indikator Ekonomi Indonesia**” merupakan data dan atau informasi yang saya peroleh melalui hasil penelitian sendiri dan tidak didasarkan pada data atau informasi hasil riset dari perusahaan/instansi/lembaga manapun.

Saya bersedia untuk bertanggung jawab secara pribadi, tanpa melibatkan pihak Universitas Bina Sarana Informatika, atas materi/isi karya ilmiah tersebut, termasuk bertanggung jawab atas dampak atau kerugian yang timbul dalam bentuk akibat tindakan yang berkaitan dengan data dan atau informasi yang terdapat pada karya ilmiah saya ini.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Jakarta  
 Pada tanggal : 03 Juli 2025  
 Yang menyatakan,

Mengetahui

Dosen Pembimbing



Ditandatangani Digital:  
 Kukuh Panggalih  
 2025-07-03 16:32:00



**Kukuh Panggalih, M.Kom**

**Sechan Aryatama**



## PENGECEKAN PLAGIARISME

Rev24\_SKRIPSI\_Sechan\_Aryatama11756\_1-1755777309865

### ORIGINALITY REPORT

|                        |                                                        |              |                |
|------------------------|--------------------------------------------------------|--------------|----------------|
| <b>19%</b>             | <b>16%</b>                                             | <b>10%</b>   | <b>8%</b>      |
| SIMILARITY INDEX       | INTERNET SOURCES                                       | PUBLICATIONS | STUDENT PAPERS |
| <b>PRIMARY SOURCES</b> |                                                        |              |                |
| <b>1</b>               | Submitted to Universitas Putera Batam<br>Student Paper |              | 1%             |
| <b>2</b>               | docplayer.info<br>Internet Source                      |              | 1%             |
| <b>3</b>               | ejournal.uksw.edu<br>Internet Source                   |              | 1%             |
| <b>4</b>               | kc.umn.ac.id<br>Internet Source                        |              | 1%             |
| <b>5</b>               | repository.bsi.ac.id<br>Internet Source                |              | 1%             |
| <b>6</b>               | ejournal.medan.uph.edu<br>Internet Source              |              | 1%             |
| <b>7</b>               | text-id.123dok.com<br>Internet Source                  |              | 1%             |
| <b>8</b>               | ejurnal.methodist.ac.id<br>Internet Source             |              | 1%             |
| <b>9</b>               | 123dok.com<br>Internet Source                          |              | <1%            |
| <b>10</b>              | repository.ubharajaya.ac.id<br>Internet Source         |              | <1%            |
| <b>11</b>              | media.neliti.com<br>Internet Source                    |              | <1%            |
| <b>12</b>              | tunasbangsa.ac.id<br>Internet Source                   |              | <1%            |

## LAMPIRAN

```
# Packages imports
import numpy as np
import pandas as pd
import scipy.stats as stats
import statsmodels.stats.api as sms
import matplotlib as mpl
import matplotlib.pyplot as plt
import seaborn as sns
from math import ceil
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler

%matplotlib inline
```

### Lampiran 1 *Import Library*

```
[ ] #Load Dataset
df_indo = pd.read_csv('indo 2010-2022.csv')

#Menampilkan 5 baris awal
df_indo.head()
```

### Lampiran 2 *Load Dataset*

```
[ ] df_indo.info()
```

### Lampiran 3 *Menampilkan Informasi*

```
[22] # ganti nama kolom
df_indo_renamed = df_indo.rename(columns={
    'REF_AREA': 'Country_Region',
    'MEASURE': 'Measure_Description',
    'FREQ': 'Observation_Frequency',
    'TIME_PERIOD': 'Year',
    'OBS_VALUE': 'nilai',
    'Unit_of measure': 'Unit_of_Measurement',
    'STRUCTURE': 'Data_Type',
    'TIMELINESS': 'Timeliness_Description',
    'DECIMALS': 'Number_of_Decimal'
})
df_indo_renamed.head()
```

#### Lampiran 4 Ganti Nama Kolom

```
[34] selected_named = df_indo_renamed[['Country_Region','Year','nilai', 'Measure_Description']]
selected_named
```

#### Lampiran 5 Menampilkan Beberapa *Data Frame*

```
[30] selected_named['Measure_Description'].unique()
```

#### Lampiran 6 Menampilkan Array

```
[32] # Melakukan pivot
df_pivot = selected_named.pivot_table(index=['Country_Region', 'Year'],
                                       columns='Measure_Description',
                                       values='nilai')

# Mengatur nama kolom
df_pivot.columns.name = None # Menghapus nama kolom yang dihasilkan oleh pivot_table
df_pivot.reset_index(inplace=True) # Mengubah index menjadi kolom biasa

df_pivot
```

#### Lampiran 7 Menampilkan Data keseluruhan

```
[ ] df_pivot.isnull().sum()
```

#### Lampiran 8 Mengecek *Missing Value*

```
[ ] #MENCARI DUPLICATE VALUES (TRUE = ADA, FALSE = TIDAK ADA)
duplicate_values = df_pivot.duplicated()
print(duplicate_values)
```

## Lampiran 9 Memeriksa Duplikat

```
[ ] #MENAMPILKAN OUTLIER (IQR)
def count_outliers_using_IQR(feature_name):
    # IQR
    Q1 = np.percentile(df_pivot[feature_name], 25, interpolation = 'midpoint')
    Q3 = np.percentile(df_pivot[feature_name], 75, interpolation = 'midpoint')

    IQR = Q3 - Q1

    # Above Upper bound
    upper = df_pivot[feature_name] >= (Q3 + 1.5 * IQR)
    # Below Lower bound
    lower = df_pivot[feature_name] <= (Q1 - 1.5 * IQR)

    print(feature_name, " : ", len(np.where(upper)[0]) + len(np.where(lower)[0]))
```

## Lampiran 10 Menampilkan Outlier

```
def count_outliers_using_zscore(feature_name, threshold=3):
    # Menghitung z-score untuk kolom fitur
    z_scores = np.abs(stats.zscore(df_pivot[feature_name]))

    # Menghitung jumlah outlier
    num_outliers = np.sum(z_scores > threshold)

    print(f"{feature_name} : {num_outliers}")

# Menghitung jumlah outlier untuk setiap fitur
print("Jumlah nilai outlier setelah penanganan untuk setiap fitur:\n")
for feature in list_of_input_features_for_outliers:
    count_outliers_using_zscore(feature)
```

## Lampiran 11 Menangani Outlier

```
[ ] import seaborn as sns
import matplotlib.pyplot as plt

# Menghapus kolom 'Year' dan menghitung korelasi
korelasi = df_pivot.drop(columns=['Year']).corr()

# Membuat heatmap korelasi
plt.figure(figsize=(10, 8))
sns.heatmap(korelasi, annot=True, cmap='coolwarm', square=True)
plt.title("Korelasi Antar Fitur (Tanpa Year)")
plt.show()
```

## Lampiran 12 Menampilkan Korelasi Antar Fitur

```

import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
from sklearn.tree import DecisionTreeRegressor, plot_tree
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt

# Asumsikan df adalah dataframe Anda
# Memilih fitur dan target
X = df_pivot[['Labour tax revenue', 'Life expectancy at birth', 'Nominal exchange rate', 'Value added']]
y = df_pivot['GDP deflator'] # atau 'Nominal exchange rate' sebagai alternatif

# Membagi data menjadi set pelatihan dan pengujian
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Model Random Forest
rf_model = RandomForestRegressor(n_estimators=100, random_state=42)
rf_model.fit(X_train, y_train)
rf_pred = rf_model.predict(X_test)

# Model Decision Tree
dt_model = DecisionTreeRegressor(max_depth=3, random_state=42)
dt_model.fit(X_train, y_train)
dt_pred = dt_model.predict(X_test)

```

### Lampiran 13 *Import Random Forest dan Decision Tree*



```

# Fungsi untuk menghitung MAPE (Mean Absolute Percentage Error)
def mean_absolute_percentage_error(y_true, y_pred):
    y_true, y_pred = np.array(y_true), np.array(y_pred)
    # Menghindari pembagian dengan nol
    mask = y_true != 0
    return np.mean(np.abs((y_true[mask] - y_pred[mask]) / y_true[mask])) * 100

# Menghitung MAPE
rf_mape = mean_absolute_percentage_error(y_test, rf_pred)
dt_mape = mean_absolute_percentage_error(y_test, dt_pred)

# Evaluasi Model
print("Random Forest Performance:")
print("MSE:", mean_squared_error(y_test, rf_pred))
print("R²:", r2_score(y_test, rf_pred))
print("MAPE:", rf_mape, "%")

print("\nDecision Tree Performance:")
print("MSE:", mean_squared_error(y_test, dt_pred))
print("R²:", r2_score(y_test, dt_pred))
print("MAPE:", dt_mape, "%")

# Visualisasi perbandingan semua Model
models = ['Random Forest', 'Decision Tree', ]
mse_values = [
    mean_squared_error(y_test, rf_pred),
    mean_squared_error(y_test, dt_pred)
]

r2_values = [
    r2_score(y_test, rf_pred),
    r2_score(y_test, dt_pred)
]

mape_values = [rf_mape, dt_mape]

# Plot perbandingan kinerja model
fig, ax = plt.subplots(1, 3, figsize=(18, 6))

# Plot MSE
bars1 = ax[0].bar(models, mse_values, color=['blue', 'green'])
ax[0].set_title('MSE Comparison')
ax[0].set_ylabel('Mean Squared Error')
ax[0].bar_label(bars1, fmt='%.2f')

# Plot R²
bars2 = ax[1].bar(models, r2_values, color=['blue', 'green'])
ax[1].set_title('R² Comparison')
ax[1].set_ylabel('R² Score')
ax[1].bar_label(bars2, fmt='%.2f')

# Plot MAPE
bars3 = ax[2].bar(models, mape_values, color=['blue', 'green'])
ax[2].set_title('MAPE Comparison')
ax[2].set_ylabel('MAPE (%)')
ax[2].bar_label(bars3, fmt='%.2f')

plt.tight_layout()
plt.show()

```

Lampiran 14 Menampilkan Hasil

UNIVERSITAS



```

# Feature importance untuk Random Forest
importances = rf_model.feature_importances_
features = X.columns
indices = np.argsort(importances)[::-1]

plt.figure(figsize=(10, 6))
plt.title('Feature Importance (Random Forest)')
bars=plt.bar(range(X.shape[1]), importances[indices], align='center')
plt.xticks(range(X.shape[1]), [features[i] for i in indices], rotation=90)
# Menambahkan nilai di atas setiap batang
for i, bar in enumerate(bars):
    height = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2., height + 0.005,
             f'{height:.2f}', ha='center', va='bottom', fontsize=10)

plt.xticks(range(X.shape[1]), [features[i] for i in indices], rotation=90)
plt.tight_layout()
plt.show()

# Visualisasi Decision Tree
plt.figure(figsize=(15, 10))
plot_tree(dt_model, feature_names=features, filled=True, rounded=True)
plt.show()

```

**Lampiran 15 Menampilkan *Feature Importance* dan *visualisasi Decision Tree***





```

# 1. Baca dataset
df = pd.read_csv("INDO 2010-2022 (2).csv")

# 2. Pilih fitur dan target
X = df[['Labour tax revenue', 'Life expectancy at birth', 'Nominal exchange rate', 'Value added']]
y = df['GDP deflator']

# 3. Split data latih & uji
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 4. Model Random Forest
rf_model = RandomForestRegressor(n_estimators=100, random_state=42)
rf_model.fit(X_train, y_train)

# 5. Model Decision Tree
dt_model = DecisionTreeRegressor(max_depth=3, random_state=42)
dt_model.fit(X_train, y_train)

# 6. Prediksi manual untuk 2023 jika tidak ada di CSV
data_2023 = df[df['Year'] == 2023][['Labour tax revenue', 'Life expectancy at birth', 'Nominal exchange rate', 'Value added']]

if not data_2023.empty:
    pred_2023_rf = rf_model.predict(data_2023)[0]
    pred_2023_dt = dt_model.predict(data_2023)[0]
else:
    manual_2023 = pd.DataFrame({
        'Labour tax revenue': [5.8],          # contoh nilai
        'Life expectancy at birth': [72.3],   # contoh nilai
        'Nominal exchange rate': [15000],    # contoh nilai
        'Value added': [55.2]                # contoh nilai
    })
    pred_2023_rf = rf_model.predict(manual_2023)[0]
    pred_2023_dt = dt_model.predict(manual_2023)[0]

else:
    manual_2023 = pd.DataFrame({
        'Labour tax revenue': [5.8],          # contoh nilai
        'Life expectancy at birth': [72.3],   # contoh nilai
        'Nominal exchange rate': [15000],    # contoh nilai
        'Value added': [55.2]                # contoh nilai
    })
    pred_2023_rf = rf_model.predict(manual_2023)[0]
    pred_2023_dt = dt_model.predict(manual_2023)[0]

print(f"\nPrediksi GDP Deflator 2023 (Random Forest): {pred_2023_rf:.2f}")
print(f"Prediksi GDP Deflator 2023 (Decision Tree): {pred_2023_dt:.2f}")

# 7. Buat DataFrame untuk plotting
years = list(df['Year']) + [2023]
rf_values = list(df['GDP deflator']) + [pred_2023_rf]
dt_values = list(df['GDP deflator']) + [pred_2023_dt]

# 8. Plot garis kurva
plt.figure(figsize=(10,6))
plt.plot(years, rf_values, marker='o', label='Random Forest', color='blue')
plt.plot(years, dt_values, marker='o', label='Decision Tree', color='green')
plt.axvline(x=2023, linestyle='--', color='red', alpha=0.7)
plt.title("Prediksi GDP Deflator hingga 2023")
plt.xlabel("Tahun")
plt.ylabel("GDP Deflator")
plt.legend()
plt.grid(True)
plt.show()

```

**Lampiran 16 Menampilkan Hasil Prediksi *GDP DEFLATOR***