

Implementasi Algoritma *Convolutional Neural Network* (CNN) Untuk Klasifikasi Jenis Tanah Berbasis Android

Yani Parti Astuti¹, Indah Wardatunizza², Egia Rosi Subhiyako^{3*)}, Etika Kartikadarma⁴
^{1,2,3,4}Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Dian Nuswantoro, Semarang
^{1,2,3,4}Jln. Imam Bonjol 207, Kota Semarang, 50131, Indonesia
 email: ¹yanipartiastuti@dsn.dinus.ac.id, ²111201912154@mhs.dinus.ac.id, ³egia@dsn.dinus.ac.id,
⁴etika.kartikadarma@dsn.dinus.ac.id

Abstract – Bawen District is one of the sub-districts in Semarang Regency, Central Java. This region has an area of land used for agriculture around 63.29%. In this area the population still uses soil as a planting medium. Soil is one of the planting media which plays an important role for the survival of plants. With so many types of soil that have different properties and characteristics, the treatment of these soils is also different. So it is necessary to have a soil classification to know how to manage the soil properly. To facilitate the classification of soil types, Deep Learning technology can be utilized with images as input which are then processed using the Convolutional Neural Network (CNN) algorithm. In order to get a model that has a high level of accuracy, an experiment was carried out on several influential parameters and an evaluation of the model was carried out using a confusion matrix. The confusion matrix has several values such as accuracy, precision, recall, and f1-score. Tests have been carried out and the results of this study are models that have a training accuracy of 97% with a loss value of 0.0880 and a testing accuracy of 95% with a loss value of 0.1513.

Abstrak – Kecamatan Bawen merupakan salah satu kecamatan yang ada di Kabupaten Semarang, Jawa Tengah. Wilayah ini memiliki luas lahan yang digunakan untuk pertanian sekitar 63,29%. Pada wilayah tersebut penduduknya masih menggunakan tanah sebagai media tanamnya. Tanah merupakan salah satu media tanam yang berperan penting untuk keberlangsungan hidup tanaman. Dengan banyaknya jenis tanah yang memiliki sifat dan karakteristik berbeda mengakibatkan perlakuan terhadap tanah tersebut juga berbeda. Sehingga perlu adanya klasifikasi tanah untuk mengetahui bagaimana mengelola tanah dengan baik. Untuk memudahkan dalam klasifikasi jenis tanah dapat memanfaatkan teknologi Deep Learning dengan gambar sebagai inputan yang kemudian di proses menggunakan algoritma Convolutional Neural Network (CNN). Untuk mendapatkan model yang memiliki tingkat akurasi tinggi dilakukan eksperimen terhadap beberapa parameter yang berpengaruh dan dilakukan evaluasi model menggunakan confusion matrix. Confusion matrix memiliki beberapa nilai seperti akurasi, precision, recall, dan f1-score. Pengujian telah dilakukan dan hasil dari penelitian ini yaitu model yang memiliki akurasi training 97% dengan nilai loss 0.0880 dan akurasi testing 95% dengan nilai loss 0.1513.

Kata Kunci – Tanah, Klasifikasi, Android, Deep Learning, Convolutional Neural Network.

I. PENDAHULUAN

Tanah dibagi menjadi beberapa jenis yaitu tanah aluvial, andosol, entisol, humus, inceptisol, laterit, kapur, dan pasir. Dengan banyaknya jenis tanah yang memiliki sifat dan

karakteristik berbeda mengakibatkan perlakuan terhadap tanah tersebut juga berbeda. Berdasarkan penelitian dari [1] jenis tanah berpengaruh pada pertumbuhan tanaman secara nyata yang mana dibuktikan pada penelitian tanaman jagung dengan membandingkan panjang akar dengan diuji oleh beberapa tanah. Untuk mengetahui jenis tanah maka bisa dilakukan dengan mengklasifikasikan sesuai dengan jenisnya melalui gambar tanah. Klasifikasi merupakan cara untuk membedakan sifat tanah dan mengelompokkannya kedalam beberapa kelas sesuai dengan kesamaan sifat yang dimiliki. Hal ini yang menjadi dasar dan acuan agar komoditas hasil pertanian dapat dikelola secara efektif dan mendapatkan hasil maksimal [2].

Seperti hasil pengamatan di Kecamatan Bawen yang memiliki luas lahan yang digunakan untuk pertanian sekitar 63,29% atau 2.947,43 ha yang diambil dari jumlah keseluruhan wilayah yaitu 4.657 ha. Pada wilayah Kecamatan Bawen penduduknya masih menggunakan tanah sebagai media tanamnya. Dari keseluruhan lahan pertanian pada wilayah Kecamatan Bawen, komoditi yang dihasilkan belum optimal seperti tinggi tanaman tidak merata, tanaman tidak berbuah padahal terlihat segar, tanaman menjadi kerdil, dan tidak jarang pula ada tanaman yang mati. Untuk mendapatkan hasil komoditas yang maksimal petani telah melakukan beberapa upaya seperti memberikan pupuk pada tanaman, pemberantasan hama, dan pemilihan bibit unggul untuk tanaman. Namun, hasil komoditas yang didapatkan tetap tidak optimal. Oleh karena itu, dalam penelitian ini akan mengklasifikasikan jenis tanah yang digunakan pada lahan pertanian di Kecamatan Bawen. Memastikan tanah dalam kondisi yang baik dan tanaman yang ditanam sesuai dengan jenis tanahnya, dapat membantu petani dalam mencapai hasil panen yang maksimal. Dengan adanya permasalahan diatas, maka harus diketahui jenis tanah yang ada di Kecamatan Bawen. Untuk mengetahuinya diperlukan pengklasifikasian berdasarkan jenisnya menggunakan data gambar. Teknik pengklasifikasian dapat menggunakan beberapa algoritma, seperti yang telah dilakukan pada penelitian sebelumnya yaitu menggunakan algoritma *K-Nearest Neighbor* (KNN)[3]–[8], Jaringan Syaraf Tiruan, *Convolutional Neural Network* (CNN)[9]–[14], *Support Vector Machine* (SVM)[15]–[18], dan *Naïve Bayes*[19]. Pada penelitian ini algoritma yang digunakan yaitu *Convolutional Neural Network* (CNN) yang merupakan bagian dari *Deep Learning*. Diantara beberapa algoritma pembelajaran *Deep Learning*, *Convolutional Neural Network* (CNN) merupakan algoritma yang sering digunakan dalam menyelesaikan permasalahan yang

*) penulis korespondensi: Egia Rosi Subhiyako
 Email: egia@dsn.dinus.ac.id

berkaitan dengan klasifikasi gambar. Dari beberapa ulasan *Convolutional Neural Network* (CNN) dinilai memiliki kinerja yang baik untuk klasifikasi data gambar dengan menjanjikan kinerja tinggi untuk berbagai masalah pertanian [20].

II. PENELITIAN YANG TERKAIT

Beberapa penelitian terkait diantaranya adalah [15] menggunakan algoritma *Support Vector Machine* (SVM) untuk klasifikasi jenis tanah menggunakan data gambar yang dilakukan di negara India. Pada penelitian ini, sebelum mengklasifikasikan jenis tanah ada tahapan *image processing* yang dilakukan dengan memperhatikan warna, energi, HSV dan lainnya. Hasil akhir dari penelitian ini yaitu berbentuk aplikasi dengan fitur seperti nutrisi tanah, rekomendasi pupuk, dan rekomendasi tanaman. Penelitian [3] membahas tentang bagaimana mengklasifikasikan jenis tanah menggunakan data gambar tanah yang ada di wilayah Langensari Kota Banjar. Pada penelitian ini metode ekstraksi ciri histogram yaitu intensitas, standar deviasi, skewness, energi, entropi, dan *smoothness* serta memanfaatkan algoritma *K-Nearest Neighbor* (KNN) untuk proses klasifikasi jenis tanahnya. Hasil akhir dari penelitian ini mendapatkan nilai akurasi tertinggi 60% pada nilai K=3 dengan jumlah data yang diuji sebanyak 20 data.

Penelitian [21] menggunakan algoritma Jaringan Syaraf Tiruan *Radial Basis Function* untuk klasifikasi jenis tanah. Pada penelitian ini dilakukan ekstraksi ciri dengan *Gray Level Co-occurrence Matrix* (GLCM) untuk kemudian dilakukan klasifikasi menggunakan algoritma Jaringan Syaraf Tiruan *Radial Basis Function*. Data yang digunakan yaitu 36 data gambar yang dibagi menjadi 21 data training dan 15 data uji. Dari hasil penelitian yang telah dilakukan GLCM terbukti sangat *powerful* untuk merepresentasikan karakteristik dari sebuah data gambar sehingga didapatkan akurasi sebesar 90,4%. Sedangkan penelitian [9] membahas tentang klasifikasi gambar daun untuk mengetahui jenis tanaman obat. Untuk klasifikasikan gambar pada penelitian ini menggunakan metode *Convolutional Neural Network* (CNN). Data yang digunakan yaitu data gambar dari beberapa daerah di Bangladesh dan juga dari sumber yang lainnya dengan total data pelatihan 34123 data. Hasil akhir penelitian ini yaitu sistem dapat mengklasifikasikan jenis tanaman obat dengan tingkat akurasi 71,3%. Penelitian lain yang relevan yakni [22] membahas tentang klasifikasi gambar motif Songket Palembang. Penelitian ini menggunakan metode ekstraksi fitur *Speeded-Up Robust Feature* (SURF) dan untuk klasifikasi gambar menggunakan metode Random Forest. Penelitian ini menggunakan 345 data gambar motif Songket Palembang seperti Bunga Cina, Cantik Manis, dan Pulir. Pembagian data untuk pembuatan model klasifikasi yaitu 300 gambar digunakan untuk data pelatihan dan 45 gambar digunakan untuk data pengujian. Hasil akhir penelitian ini mampu mengklasifikasikan gambar motif Songket Palembang dengan baik. Untuk motif Bunga Cina didapatkan *precision* dan *recall* sebesar 66,67% serta untuk nilai *accuracy*nya sebesar 77,78%. Untuk motif Cantik Manis nilai *precision*nya sebesar 72,72%, nilai *recall* sebesar 53,33% dan *accuracy*nya sebesar 77,78%. Untuk motif Pulir nilai *precision*nya sebesar 68,48%, nilai *recall* sebesar 86,67%, dan *accuracy*nya sebesar 82,22%. Jadi secara keseluruhan

didapatkan akurasi untuk Bunga Cina 66,67%, Cantik Manis 55,33% dan Pulir 86,67%.

III. METODE PENELITIAN

A. Prosedur Pengambilan dan Pengumpulan Data


1. Studi Literatur

Data yang digunakan yaitu menggunakan data publik yang diambil dari website Kaggle. Datasets tersebut berjumlah 880 data gambar jenis tanah yang dibagi menjadi 8 kelas yaitu aluvial, andosol, entisol, humus, inceptisol, laterit, kapur, dan pasir. Data gambar jenis tanah berformat jpg dan png dengan 3 channel RGB.

2. Observasi

Pengambilan data tanah yaitu pada wilayah Kecamatan Bawen Provinsi Jawa Tengah. Data gambar diambil melalui kamera smartphone dengan spesifikasi kamera 13 MP. Cara pengambilan gambar yaitu smartphone diletakkan pada jarak 10 cm dari sisi atas. Pengambilan data sebanyak 10 sample data tanah yang diambil dari 10 tempat yang berbeda. Data yang didapatkan akan diidentifikasi dengan memilih gambar yang berkualitas baik.

B. Teknik Analisis Data




Gbr. 1 Alur Teknik Analisis Data

Gbr. 1 menunjukkan alur teknik analisis data, dimulai dengan dataset original yang diubah ukurannya, kemudian dilakukan normalisasi data, split data dan terakhir adalah augmentasi gambar.

C. Metode yang diusulkan

Pemilihan metode CNN karena hasil dari penelitian terkait menyatakan bahwa metode ini mampu mengklasifikasikan data yang memiliki inputan berupa data gambar. Dalam pembuatan model CNN memanfaatkan library *TensorFlow* dan *Keras*. Alur penelitian menggunakan metode CNN direpresentasikan pada Gbr 2.



Gbr 2. Alur Penelitian

D. Eksperimen dan Pengujian Model

1. Eksperimen

Eksperimen atau percobaan dilakukan dengan melakukan perubahan pada layer konvolusi dan layer pooling, melakukan perubahan nilai pada layer *dropout*, menggunakan 3 *optimizer* seperti SGD, RMSProp, Adam, menggunakan nilai learning rate yang berbeda. Dari percobaan tersebut memiliki tujuan untuk mendapatkan model yang memiliki tingkat akurasi tinggi.

2. Pengujian

Pengujian model dilakukan dengan dua cara yaitu menggunakan *confusion matrix* dan pengujian manual melalui aplikasi android. *Confusion matrix* akan menghasilkan beberapa nilai seperti nilai akurasi, *precision*, *recall* dan *f1-score*. Sedangkan untuk pengujian manual akan menghasilkan nilai keterangan sesuai atau tidak sesuai pada gambar yang diambil melalui kamera *smartphone*.

IV. HASIL DAN PEMBAHASAN

Pada penelitian ini, kami melakukan klasifikasi 8 kelas gambar jenis tanah yaitu tanah aluvial, andosol, entisol, humus, inceptisol, kapur, laterit, dan pasir dengan menggunakan algoritma *Convolutional Neural Network* (CNN). Data yang digunakan dalam penelitian ini dibagi menjadi 3 bagian yaitu *data train*, *data validation* dan data testing. *Data training* dan *data validation* digunakan dalam pembuatan model, sedangkan untuk data testing digunakan dalam pengujian model. Setelah model berhasil dibangun yang digunakan untuk menunjukkan keberhasilan suatu model adalah nilai akurasi. Nilai akurasi ini didapatkan dari hasil pengujian model dengan menggunakan data testing.

3.1 Dataset

Dataset yang digunakan adalah data gambar jenis tanah yaitu tanah aluvial, andosol, entisol, humus, inceptisol, kapur, laterit, dan pasir. Dataset yang diambil melalui Kaggle berjumlah 880 gambar dengan jumlah pada masing-masing

kelas adalah 110 data gambar. Selain itu pada penelitian ini juga menggunakan dataset yang diambil pada wilayah Kecamatan Bawen. Pengambilan data menggunakan kamera *smartphone*.

3.2 Preprocessing data

Tahapan preprocessing yang dilakukan yaitu *resize*, normalisasi data, membagi data dan data augmentasi.

a. *Resize image*

Resize image yang dilakukan yaitu mengubah dimensi gambar menjadi berukuran 150×150 .

b. Normalisasi Data

Normalisasi data yang dilakukan yaitu mengubah nilai X dan Y. Untuk nilai X menjadi memiliki rentang dari 0-1. Sedangkan untuk nilai Y menjadi memiliki nilai dari 0-7 berdasarkan kelas yang ada.

c. Membagi data

Dataset jenis tanah yang diambil dari kaggle akan digunakan untuk pembuatan model. Dataset tersebut dibagi menjadi data training 80%, data validation 10% dan data testing 10%. Pembagian data adalah dengan membagi jumlah data training 704 data gambar, data validation 88 data gambar, data testing 88 data gambar.

d. Augmentasi data

Data augmentasi menggunakan parameter *rotation_range*, *zoom_range*, *width_shift_range*, *height_shift_range*, *horizontal_flip*.

3.3 Pembuatan Model

Untuk mendapatkan model yang memiliki akurasi tinggi adalah dengan melakukan percobaan mengubah parameter model yang berpengaruh untuk peningkatan akurasi.

1. Pengaruh jumlah layer konvolusi

TABEL 1 PENGARUH JUMLAH LAYER KONVOLUSI

Layer	Accuracy	Loss
1 layer konvolusi	88%	0.2677
2 layer konvolusi	89%	0.3158
3 layer konvolusi	95%	0.1513
4 layer konvolusi	94%	0.1396
5 layer konvolusi	88%	0.4038

Tabel 1 menunjukkan dapat disimpulkan bahwa banyaknya layer yang digunakan dalam pembuatan model berpengaruh pada nilai akurasi yang dihasilkan. Pada penelitian ini akan menggunakan 3 layer konvolusi dengan nilai akurasi 95% dan nilai loss 0.1513.

2. Pengaruh pooling layer

TABEL 2 PENGARUH POOLING LAYER

Pooling Layer	Accuracy	Loss
Average Pooling	95%	0.1513
Max Pooling	85%	0.9970

Tabel 2 menunjukkan pengaruh pooling layer, dan pada penelitian ini metode *pooling* yang akan digunakan yaitu *average pooling* dengan nilai akurasi 95% dan nilai *loss* 0.1513.

3. Pengaruh nilai layer dropout

TABEL 3 PENGARUH NILAI LAYER DROPOUT

Layer Dropout	Accuracy	Loss
Tanpa dropout	95%	0.1513
0	88%	0.3180
0.25	94%	0.2062
0.5	93%	0.2166
0.75	88%	0.3047

Tabel 3 menunjukkan pengaruh nilai layer dropout, sehingga pada penelitian ini akan menggunakan model tanpa nilai dropout. Hal ini dikarenakan hasil akurasi model yang tanpa menggunakan layer dropout lebih tinggi dibandingkan dengan yang menggunakan layer dropout dengan akurasi 95% dan loss 0.1513.

4. Pengaruh optimizer

TABEL 4 PENGARUH OPTIMIZER

Optimizer	Accuracy	Loss
Adam	95%	0.1513
SGD	84%	0.6532
RMSprop	94%	0.1927

Berdasarkan Tabel 4 untuk mendapatkan model yang baik parameter optimizer yang digunakan yaitu Adam karena memiliki nilai akurasi tertinggi yaitu 95% dan nilai loss yang rendah yaitu 0.1513.

5. Pengaruh learning rate

TABEL 5 PENGARUH LEARNING RATE

Learning Rate	Accuracy	Loss
0.001	95%	0.1513
0.003	90%	0.3710
0.005	86%	0.4992
0.0001	87%	0.3494
0.0003	94%	0.1621
0.0005	92%	0.2131

Berdasarkan Tabel 5 nilai learning rate yang paling baik yang digunakan untuk membuat model akhir yaitu 0.001 karena memiliki akurasi yang tinggi jika dibandingkan dengan nilai learning rate yang lain yaitu sebesar 95% dengan nilai loss 0.1513.

6. Pengaruh jumlah epoch

TABEL 6 PENGARUH JUMLAH EPOCH

Jumlah epoch	Accuracy	Loss
10	62%	0.9106
30	30%	0.5295
50	50%	0.3041
75	90%	0.2333
100	95%	0.1513

Berdasarkan Tabel 6, dengan bertambahnya jumlah epoch akurasi juga semakin bertambah namun pada jumlah epoch yang banyak meningkatnya tidak terlalu signifikan. Jadi pada penelitian ini akan menggunakan nilai epoch 100 untuk mendapatkan akurasi yang cukup tinggi dan memiliki nilai loss rendah.

Dari hasil percobaan yang dilakukan berulang kali dengan beberapa nilai berbeda yang diberikan pada parameter model didapatkan satu model yang akan digunakan untuk klasifikasi jenis tanah. Pada penelitian ini menggunakan input gambar dengan ukuran $150 \times 150 \times 3$. Kemudian parameter yang berhasil mendapatkan akurasi tinggi dan nilai loss rendah yaitu menggunakan 3 layer konvolusi, tanpa menggunakan layer dropout, menggunakan layer pooling berupa average pooling, menggunakan optimizer adam, menggunakan nilai learning rate 0.001, dan jumlah epoch untuk training adalah 100.


3.4 Evaluasi Model

Confusion matrix memiliki beberapa nilai seperti akurasi, precision, recall, dan f1-score. Pada Gambar 3 ditunjukkan nilai dari dari confusion matrix pada tiap kelasnya. Didapatkan nilai akurasinya secara keseluruhan 95%, nilai precision secara keseluruhan 93%, nilai recall secara keseluruhan 95%, nilai f1-score secara keseluruhan 93%.

	precision	recall	f1-score	support
Aluvial	0.57	0.80	0.67	5
Andosol	0.88	1.00	0.93	7
Entisol	1.00	1.00	1.00	16
Humus	1.00	1.00	1.00	12
Inceptisol	1.00	1.00	1.00	10
Laterit	1.00	0.77	0.87	13
Kapur	1.00	1.00	1.00	15
Pasir	1.00	1.00	1.00	10
accuracy			0.95	88
macro avg	0.93	0.95	0.93	88
weighted avg	0.97	0.95	0.96	88

Gbr 3. Nilai Confusion Matrix

Gbr 4 menunjukkan implementasi pada aplikasi android



Gbr 3. Hasil aplikasi android

Model yang memiliki akurasi paling tinggi diconvert dengan format .tflite kemudian model tersebut diimplementasikan pada aplikasi android. Pengujian aplikasi menggunakan dataset hasil observasi yang berjumlah 10 data tanah. Hasil pengujian aplikasi ditunjukkan pada Tabel 7.

TABEL 7 HASIL PENGUJIAN APLIKASI

NO	Gambar	Hasil Klasifikasi	Keterangan
1		Jenis tanah Pasir	Tidak Sesuai
2		Jenis tanah Andosol	Tidak Sesuai
3		Jenis tanah Andosol	Sesuai
4		Jenis tanah Andosol	Sesuai
5		Jenis tanah Aluvial	Sesuai
6		Jenis tanah Aluvial	Sesuai
7		Jenis tanah Andosol	Sesuai

NO	Gambar	Hasil Klasifikasi	Keterangan
8		Jenis tanah Aluvial	Sesuai
9		Jenis tanah Andosol	Sesuai
10		Jenis tanah Andosol	Sesuai

Berdasarkan hasil pengujian pada Tabel 7 dari 10 data gambar tanah didapatkan 8 data sudah sesuai hasil klasifikasi dan 2 data tidak sesuai dengan hasil klasifikasi. Pada gambar nomor 1 seharusnya tanah tersebut adalah tanah inceptisol, namun pada hasil klasifikasi gambar tersebut diklasifikasikan ke dalam tanah pasir. Pada gambar nomor 2 seharusnya tanah tersebut diklasifikasikan ke dalam tanah aluvial, namun pada hasil klasifikasi gambar tersebut diklasifikasikan ke dalam tanah andosol. Hal ini terjadi karena gambar jenis tanah inceptisol dan jenis tanah pasir yang ada pada dataset memiliki kemiripan warna sehingga nilai fitur yang dihasilkan kedua gambar tersebut memiliki nilai yang hampir sama. Begitu juga dengan gambar jenis tanah aluvial dan jenis tanah andosol juga memiliki warna yang hampir sama sehingga memungkinkan hasil klasifikasi yang tidak sesuai.

V. KESIMPULAN

Klasifikasi jenis tanah berbasis android menggunakan algoritma *Convolutional Neural Network* (CNN) telah berhasil dibuat dan dapat menampilkan hasil klasifikasi gambar jenis tanah. Algoritma CNN yang diterapkan pada klasifikasi gambar jenis tanah menggunakan input shape 150×150 , nilai learning rate 0.001, ukuran filter 3×3 , jumlah epoch 100, data training 704, data validation 88 menghasilkan akurasi training sebesar 97% dan akurasi testing 95%. Pada pengujian secara manual menggunakan aplikasi android dengan data dari hasil observasi didapatkan dari 10 gambar 8 diklasifikasikan dengan benar dan 2 gambar salah klasifikasi. Dari penelitian yang sudah dilakukan masih perlu adanya pengembangan untuk mendapatkan hasil yang lebih baik lagi. Pada penelitian selanjutnya diharapkan dapat penambahan jumlah data dari masing-masing kelas dan dapat menggunakan metode lainnya seperti transfer learning untuk peningkatan performa model CNN yang telah dibangun.

DAFTAR PUSTAKA

- [1] Genesiska, Mulyono, dan A. Intan Yufantari, "Pengaruh Jenis Tanah Terhadap Pertumbuhan dan Hasil Tanaman Jagung (*Zea mays* L.) Varietas Pulut Sulawesi Effect of Soil Type on the Growth and Yield of Maize (*Zea mays* L.) Var. Pulut Sulawesi," *J. Agric. Sci.*, vol. 2020, no. 2, hal. 107–117, 2020.
- [2] I. Erliana, Abubakar, dan Zainabun, "Klasifikasi Tanah Kebun Kopi Arabika di Kabupaten Gayo Lues Berdasarkan Sistem Klasifikasi Soil Taxonomy USDA (Soil Classification of Arabica Coffee Farms on Gayo Lues Based on the USDA Soil Taxonomy Calssifikasi System)," *J. Ilm. Mhs. Pertan.*, vol. 7, no. 1, hal. 696–703, 2022, [Daring]. Tersedia pada: www.jim.unsyiah.ac.id/JFP.
- [3] R. Rudi dan D. Avianto, "Implementasi Ekstraksi Ciri Histogram dan K-Nearest Neighbor untuk Klasifikasi Jenis Tanah di Kota Banjar, Jawa Barat," *J. Buana Inform.*, vol. 10, no. 2, hal. 85, 2019, doi: 10.24002/jbi.v10i2.2141.
- [4] D. S. Jodas, L. A. Passos, A. Adeel, dan J. P. Papa, "PL-kNN: A Python-based implementation of a parameterless k-Nearest Neighbors classifier [Formula presented]," *Softw. Impacts*, vol. 15, no. December 2022, hal. 100459, 2023, doi: 10.1016/j.simpa.2022.100459.
- [5] L. M. Riza Rizky dan S. Suyanto, "Adversarial training and deep k-nearest neighbors improves adversarial defense of glaucoma severity detection," *Heliyon*, vol. 8, no. 12, hal. e12275, 2022, doi: 10.1016/j.heliyon.2022.e12275.
- [6] Z. Xu, J. Cao, G. Zhang, X. Chen, dan Y. Wu, "Active learning accelerated Monte-Carlo simulation based on the modified K-nearest neighbors algorithm and its application to reliability estimations," *Def. Technol.*, no. xxxx, 2022, doi: 10.1016/j.dt.2022.09.012.
- [7] M. Cubillos, S. Wöhlk, dan J. N. Wulff, "A bi-objective k-nearest-neighbors-based imputation method for multilevel data," *Expert Syst. Appl.*, vol. 204, no. April, 2022, doi: 10.1016/j.eswa.2022.117298.
- [8] J. A. Romero-del-Castillo, M. Mendoza-Hurtado, D. Ortiz-Boyer, dan N. García-Pedrajas, "Local-based k values for multi-label k-nearest neighbors rule," *Eng. Appl. Artif. Intell.*, vol. 116, no. October, hal. 105487, 2022, doi: 10.1016/j.engappai.2022.105487.
- [9] R. Akter dan M. I. Hosen, "CNN-based Leaf Image Classification for Bangladeshi Medicinal Plant Recognition," *ETCCE 2020 - Int. Conf. Emerg. Technol. Comput. Commun. Electron.*, 2020, doi: 10.1109/ETCCE51779.2020.9350900.
- [10] L. Pérez-Sala, M. Curado, L. Tortosa, dan J. F. Vicent, "Deep learning model of convolutional neural networks powered by a genetic algorithm for prevention of traffic accidents severity," *Chaos, Solitons and Fractals*, vol. 169, no. October 2022, hal. 113245, 2023, doi: 10.1016/j.chaos.2023.113245.
- [11] T. Rahman dan M. S. Islam, "MRI brain tumor detection and classification using parallel deep convolutional neural networks," *Meas. Sensors*, vol. 26, no. October 2022, hal. 100694, 2023, doi: 10.1016/j.measen.2023.100694.
- [12] M. Ishida, N. Kaneko, dan K. Sumi, "MOJI: Character-level convolutional neural networks for Malicious Obfuscated JavaScript Inspection," *Appl. Soft Comput.*, vol. 137, hal. 110138, 2023, doi: 10.1016/j.asoc.2023.110138.
- [13] A. S. Annuar, R. A. Rahman, A. Munir, A. Murad, H. A. El-enshasy, dan R. Illias, "Jo ur l P re," *Carbohydr. Polym.*, hal. 118159, 2021, doi: 10.1016/j.net.2023.03.025.
- [14] A. Osborne, J. Dorville, dan P. Romano, "Energy and AI Upsampling Monte Carlo neutron transport simulation tallies using a convolutional neural network ☆," *Energy AI*, vol. 13, no. March, hal. 100247, 2023, doi: 10.1016/j.egyai.2023.100247.
- [15] H. K. Sharma dan S. Kumar, "Soil Classification Characterization Using Image Processing," *Proc. 2nd Int. Conf. Comput. Methodol. Commun. ICCMC 2018*, no. Iccmc, hal. 885–890, 2018, doi: 10.1109/ICCMC.2018.8488103.
- [16] A. Hu, H. Liao, W. Guan, J. Dong, dan X. Qian, "Support vector machine model based on OTSU segmentation algorithm in diagnosing bronchiectasis with chronic airway infections," *J. Radiat. Res. Appl. Sci.*, vol. 16, no. 1, hal. 100500, 2023, doi: 10.1016/j.jrras.2022.100500.
- [17] M. P. Behera, A. Sarangi, dan D. Mishra, "ScienceDirect ScienceDirect A Hybrid Machine Learning algorithm for Heart and Liver Disease A Hybrid Machine for Heart and Liver Disease Prediction Using Learning Modified algorithm Particle Swarm Optimization with Prediction Using Modified Particle Swarm Optimization with Support Vector Machine Support Vector Machine," *Procedia Comput. Sci.*, vol. 218, no. 2022, hal. 818–827, 2023, doi: 10.1016/j.procs.2023.01.062.
- [18] D. K. Jana, P. Bhunia, S. Das Adhikary, dan A. Mishra, "Analyzing of salient features and classification of wine type based on quality through various neural network and support vector machine classifiers," *Results Control Optim.*, vol. 11, no. February, hal. 100219, 2023, doi: 10.1016/j.rico.2023.100219.
- [19] Y. N. Paseneke dan A. Nugroho, "Pemetaan dan Klasifikasi Kesesuaian Jenis Tanah Terhadap Tanaman Menggunakan Metode Naïve Bayes di Desa Cukilan," *Aiti*, vol. 19, no. 2, hal. 199–212, 2022, doi: 10.24246/aiti.v19i2.199-212.
- [20] Y. Liu, H. Pu, dan D. W. Sun, "Efficient extraction of deep image features using convolutional neural network (CNN) for applications in detecting and analysing complex food matrices," *Trends Food Sci. Technol.*, vol. 113, no. April, hal. 193–204, 2021, doi: 10.1016/j.tifs.2021.04.042.
- [21] E. Y. Puspaningrum, B. Nugroho, dan H. A. Manggala, "Penerapan Radial Basis Function Untuk Klasifikasi Jenis Tanah," *SCAN - J. Teknol. Inf. dan Komun.*, vol. 15, no. 1, hal. 46–49, 2020, doi: 10.33005/scan.v15i1.1852.
- [22] Y. Yohannes, S. Devella, dan A. H. Pandrean, "Penerapan Speeded-Up Robust Feature pada Random Forest Untuk Klasifikasi Motif Songket Palembang," *J. Tek. Inform. dan Sist. Inf.*, vol. 5, no. 3, hal. 360–369, 2020, doi: 10.28932/jutisi.v5i3.1978.